PROYECTO DE ESTADÍSTICA MULTIVARIADA: CLASIFICACIÓN DE LAS VARIABLES QUE PREDICEN LA CALIDAD DEL AIRE.



Fernando Garcia Gualito

INTRODUCCIÓN

La calidad del aire en las zonas industriales y en las grandes metropolis están afectando demasiado a la salud de las personas que viven en ellas o sus alrededores. "La contaminación del aire impacta la salud humana, el bienestar y el medio ambiente. Ha sido un problema ampliamente reconocido durante los últimos 50 años (Gurjar et al., 2008; Ozden et al., 2008)." Para estas personas es muy peligroso ya que se sabe que los gases tóxicos y aire contaminado pueden ocasionar diversas afecciones y enfermedades crónicas. Los estudios previos sobre contaminación industrial del aire se han asociado con asma infantil, bajo peso al nacer y enfermedades cardiovasculares (Zeng y He, 2019; Bergstra et al., 2021; Vega et al., 2021, citado en (Yadav et al., 2022).

El dióxido de Carbono y azufre, asi como el Ozono Troposférico, PM10 y monóxido de carbono son compuestos químicos muy importantes para el estudio de su impacto en la calidad del aire; Según(Flemming, 2005) O3, NO2, SO2 y PM10 (material particulado con diámetros de partícula o 10 mm) son especies objetivo de la Directiva Marco de la Unión Europea sobre la evaluación de la calidad del aire ambiental (AQ), debido a sus efectos negativos en la salud humana y la vegetación (Directiva Marco CE 96/62/CE).

Solo basta mirar el caso de malasia que desde el año 1989 han usado el indice de contaminación del aire basado en 5 criterios de contaminación respecto a los gases tóxicos como lo son: *PM10, SO2, NO2, CO y O3. Y del mas alto valor de estos índices individuales de los contaminantes se deduce la calidad del Aire en la zona.(Dominick, et. al., 2012)*

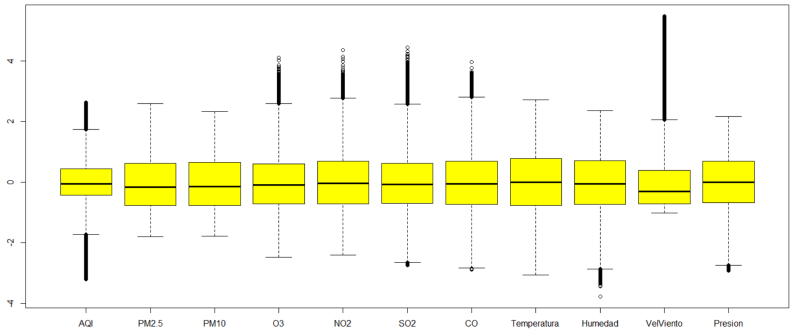
Mayormente las pruebas o análisis no se realizan directamente con emisiones de gases contaminantes ya que son más difíciles de estimar y son por mucho mas subjetivas, en el caso de las concentraciones de estos gases son una mejor opción para poder hacer un análisis con reglas de clasificación.(Flemming, 2005)

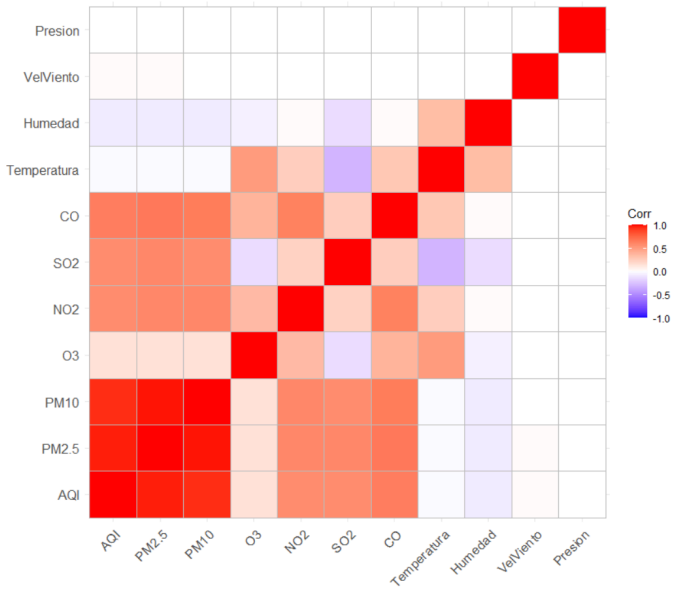
En este proyecto se tratará de dar una buena interpretación a los datos que se brindaron por medio de dos buenas metodologías de analisis de datos multivariados. Se busca hallar una clasificación y correspondencia entre variables que están relacionadas en el tema de calidad del aire, y es que como menciona(Flemming, 2005) "La motivación para desarrollar un nuevo esquema de clasificación surgió de la constatación, obtenida a través de estudios de evaluación de modelos de transporte de contaminantes, de que la clasificación de los regímenes de O3 a menudo no es adecuada para distinguir los regímenes correspondientes de SO2, PM10 y, en algunos casos, NO2, ya que estos contaminantes no están necesariamente asociados con las mismas fuentes de emisión o mecanismos químicos de producción. Y más allá de todo esto ya mencionado podemos contar con otras variables como temperatura, presión y humedad del ambiente, así como velocidad del aire. Haremos aún más interesante este análisis.

ANÁLISIS DE COMPONENTES PRINCIPALES PARA EL CONJUNTO DE DATOS: Calidad del aire

El análisis de componentes principales es uno de los más usados en estadística multivariante ya que ayuda a reducir dimensiones, eliminando la mínima variabilidad de los datos originales a coste de indicadores que no son significativos en el análisis.(Azid et al., 2014). Para este caso donde tenemos datos de la calidad del aire es muy importante para comenzar a explorar y descubrir patrones de las concentraciones de gases y las condiciones climatológicas también. El Análisis de Componentes Principales (PCA) (Jolliffe, 2002) es el método más ampliamente utilizado para analizar las fuentes de varianza y los patrones de variación de los conjuntos de datos ambientales.

Como primer paso entendamos las variables y observemos las correlaciones entre ellas. Podemos notar en la primera figura como la mayoría de datos del dataset están dispersos muy cerca de la media 0 (datos ya normalizados)
Pero hay outliers muy pronunciados en las variables velocidad del viento, que interpretandolo suele sonar normal, al igual que algunos de concentraciones de O3, NO2 y SO2.

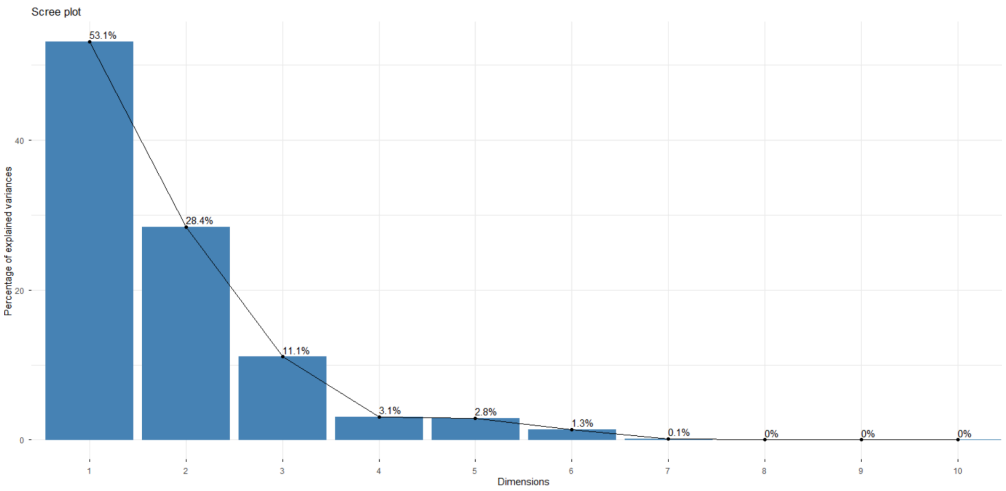


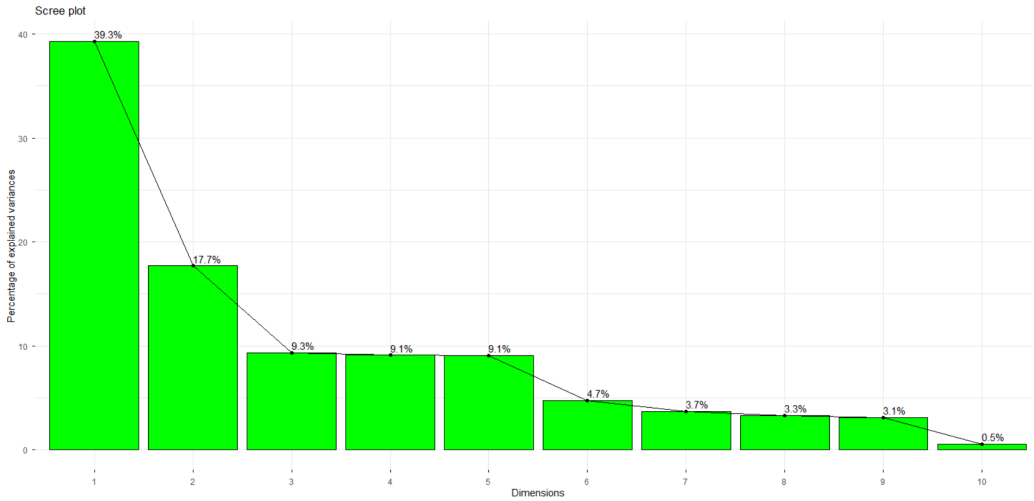


En cuestión a la segunda figura, vemos las correlaciones entre las variables teniendo mayormente correlaciones positivas que son significativas, a excepción de si acaso la Temperatura con el SO2. La parte que más llama la atención son la correlación entre las variables PM10,PM2.5 y AQI(índice de calidad del aire). Recordando que el PM es Material particulado que se encuentra en forma solida e incluso liquida que puede encontrarse de forma libre en la atmosfera. Como cita (Rojas,2022) "pudiendo dispersarse a partir de fuentes naturales (partículas de polvo del desierto, aerosoles de sal marina, incendios forestales) o procesos de combustión,

actividades industriales y calefacción comunitaria" (OECD, 2001). E incluso estas ultimas 3 variables estan directamente relacionadas con las concentraciones de NO2, SO2 y CO.

PORCENTAJE DE VARIANZA EXPLICADA POR LOS COMPONENTES PRINCIPALES:





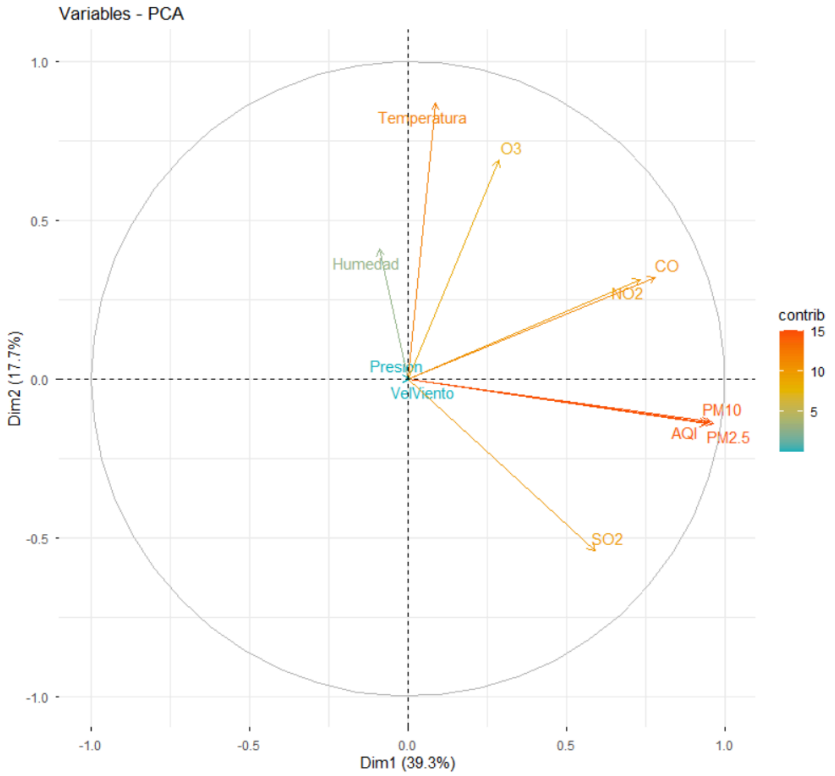
	CP1	CP2	CP3	CP4	CP5	CP6	CP7	CP8	CP9	CP10	CP11
Desviación E.	*0.9040*	*0.4999*	*0.3078*	*0.3007*	*0.1911*	*0.1287*	*0.1089*	*0.1028*	*0.0177*	*0.0005*	*0*
Proporción de varianza	*0.6152*	*0.1881*	*0.0713*	*0.0681*	*0.0275*	*0.0124*	*0.0089*	*0.0079*	*0.0002*	*0.00005*	*0*
Proporción acumulada.	*0.6152*	*0.8033*	*0.8747*	*0.9428*	*0.97*	*0.98*	*0.991*	*0.999*	*0.9997*	*0.99999*	*1*

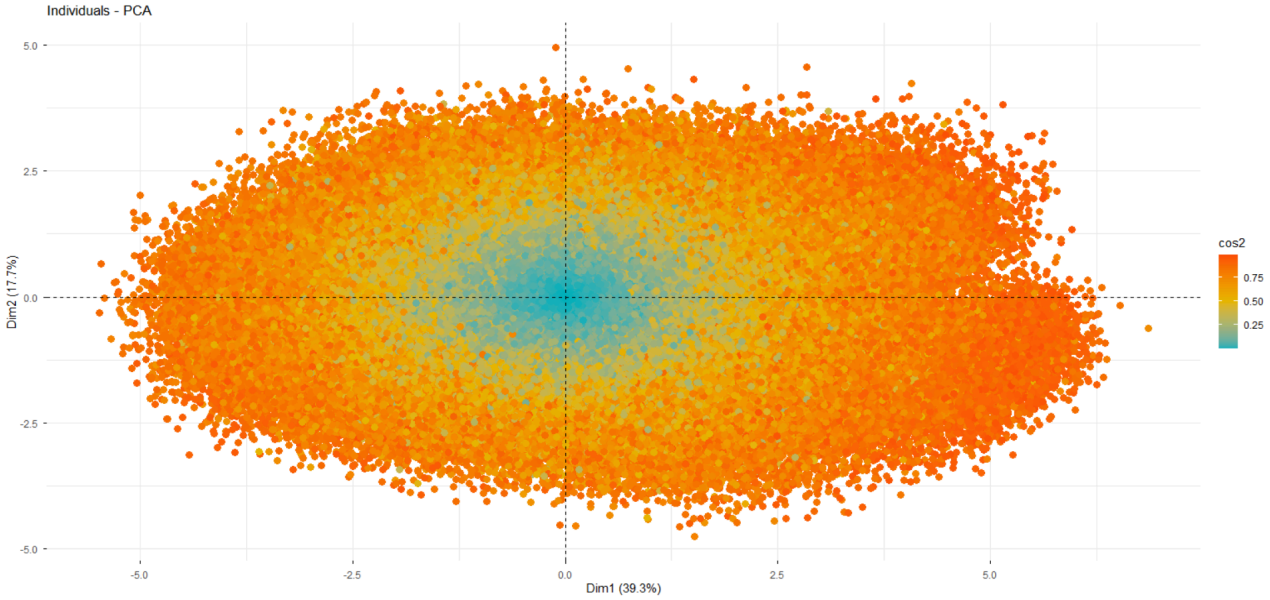
Se eligió trabajar con las primeras dos componentes principales.Según (Yadav et al., 2019a) "El primer PC describe la máxima variabilidad, y los PC posteriores están relacionados con la variabilidad que no fue explicada por los PC anteriores" Los primeros 2 componentes ya explicaban el 80% de los datos.
Mire en las siguientes tablas las contribuciones (coeficientes) de las variables en las componentes principales, cada tabla se realizó con un método distinto. En donde miramos que el primer componente es bien representado por el Índice de calidad de aire, las partículas PM2.5 y PM10 así como NO2, CO y SO2.
Por su parte, el componente 2 tiene considerables cargas en las variables: O3, Temperatura ySO2.

```
> res = PCA(datos, scale.unit = TRUE, n
> res$var$coord[, 1:2]
                  Dim.1         Dim.2
AQI          0.944465920 -1.407816e-01
PM2.5        0.963484651 -1.396700e-01
PM10         0.951715450 -1.357448e-01
O3           0.287576487  6.890450e-01
NO2          0.733877144  3.136588e-01
SO2          0.589813171 -5.416075e-01
CO           0.780397226  3.188111e-01
Temperatura  0.087919672  8.681706e-01
Humedad     -0.091385663  4.081184e-01
VelViento    0.005791969 -1.853726e-04
Presion      0.004827128 -7.851238e-05
```

```
> datosacp$loadings[, 1:2]
                Comp.1      Comp.2
AQI          0.45137596  0.02885592
PM2.5        0.45919149  0.03146134
PM10         0.45326638  0.03279181
O3          -0.03305374  0.52426474
NO2          0.25650335  0.32095758
SO2          0.36152750 -0.33543127
CO           0.27674639  0.33185645
Temperatura -0.19707706  0.53411771
Humedad     -0.21753930  0.08237485
VelViento   -0.09871535 -0.22840398
Presion     -0.09933711 -0.22881512
```

Aquí tenemos representaciones gráficas de la importancia de las variables en las 2 dimensiones, y sus pesos en cada uno de ellos; Es decir los coeficientes de los dos primeros términos de la ecuación de $Yi = ai1x1 + ai2x2 + \cdots + aipxp$*. Así como la variabilidad de datos individuales en 2 componentes.. Suponiendo cada punto como como elementos dij descompuesto como la suma de varios componentes cada uno definido como productos de puntuaciones(xi) y cargas(yi).(Playikanov2022)*



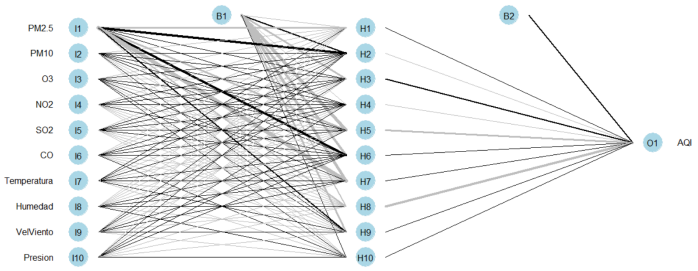

Individuals - PCA
Dim2 (17.7%)
Dim1 (39.3%)
5.0
2.5
0.0
-2.5
-5.0
cos2
0.75
0.50
0.25

ANÁLISIS CON REDES NEURONALES:

Las redes neuronales artificiales son una herramienta con la que se aprenden procesos con base a funciones cerebrales humanas y que tienen como objetivo la predicción de diferentes clases.(Chiñas, et.al.(2013)) Está basado en un conjunto de pilares de activación a los cuales llamaremos nodos. “Pueden ser utilizadas para resolver problemas de reconocimiento de patrones tanto supervisados como no supervisados” (Soler, 2007). Una red neuronal aprende y se adapta a nuevas señales que reciba paso a paso, así indicar patrones que se pueden interpretar de forma objetiva en distintos ámbitos como el ambiental.

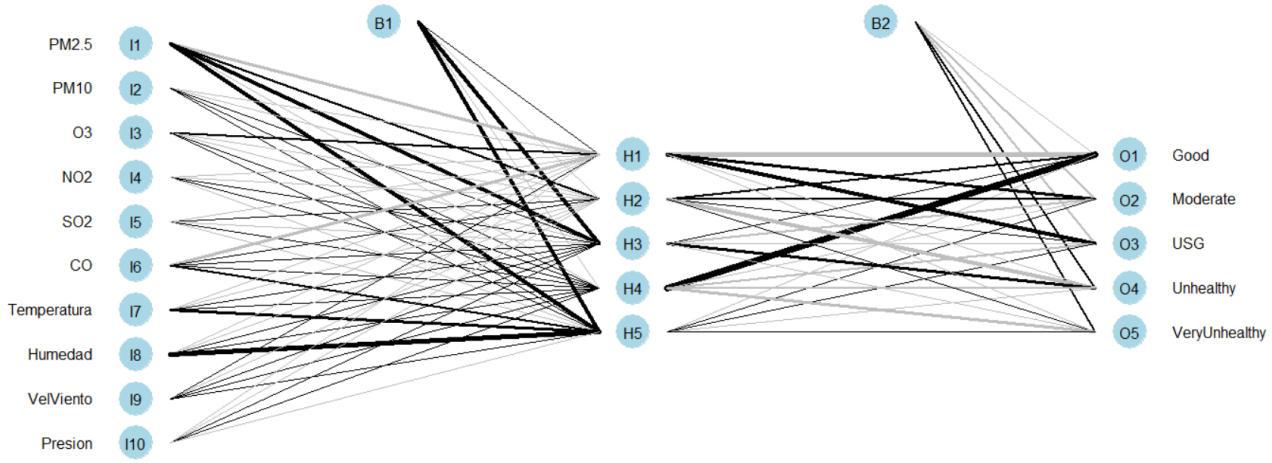
Se hará uso del programa r , al igual que con el análisis de componentes principales para ejecutar algunas redes neuronales entre nuestras variables de interés. Para esto y nuestro dataset de más de 225,000 observaciones se tomo una muestra de 30000 con la que se entrenó con un 80% de la muestra y se tuvo de prueba un 20% para después revisar predicciones.

Primero se realizó un modelo con valores continuos de la variable calidad del aire, este con 10 neuronas ocultas y salida como ya se mencionó con salida continua:



Después de categorizar los valores que podia tomar el indice de calidad de aire, todo esto con ayuda de la función nnet y Neurotools de r.

Después se compararon los datos de prueba y entrenamiento teniendo una muy buena precisión a la hora de predecir y categorizar dentro de la red para poder obtener patrones indicadoras respecto a las variables que tenemos y los tipos de calidad de aire.



Así como lo hace la técnica simple del perceptrón, comparando la salida que tiene un elemento y generarlo dependiendo a que clase debería tener, aunque esta técnica solo sea para clasificación binaria.El proceso de entrenamiento inicia con una inicialización de pesos, que pueden asignarse de forma aleatoria o en cero para mantener una base común. Sin embargo, este tipo de red únicamente puede resolver problemas linealmente separables, es decir, aquellos donde el espacio de entrada puede dividirse mediante un hiperplano que separe ambas clases. En esta investigación, dicho algoritmo se emplea considerando los parámetros propuestos para este tipo de modelos (Haykin, 2003).

TABLA DE CONFUSIÓN:

	Bueno	*Moderado*	*D. para G.S*	*D. para la salud*	*Muy dañino*	*Peligroso*
Bueno	*47*	*0*	*0*	*0*	*0*	*0*
Moderado	*0*	*362*	*0*	*0*	*0*	*0*
D. para G.S.	*0*	*1*	*763*	*1*	*0*	*0*
D. para la salud	*0*	*0*	*7*	*3582*	*0*	*0*
Muy dañino	*0*	*0*	*0*	*1*	*1236*	*0*
Peligroso	*0*	*0*	*0*	*0*	*0*	*0*

CONCLUSIONES

Hemos explorado antes que nada gracias a la técnica de Analisis de Componentes principales que variables probablemente puedan tener más relaciones entre ellas, esto por que cuando vemos los puntos o individuos que se mantuvieron en las dimensiones de los componente principales seleccionados, pues estos suelen compartir cargas y parecerse demasiado, lo cual los relaciona y suele llevar a querer estudiarlos más a fondo. Como es el caso de el PM10, P2.5 y el Indice de Calidad del aire, que como después confirmamos en redes neuronales tienen una gran correlación al momento de que los niveles de estas dos materiales particulados son muy altos y que como tambien ya se leyo en algunos artículos es muy dañino para la salud. Ambas variables tienen cargas muy fuertes en la primera componente principal y apuntan a la misma dirección lo que nos hace ver que hay que tener mucho más control de estas partículas para cuidar el aire y la salud humana. Por otra parte se observó una semejanza entre la varianza de las variables Temperatura y O3 las cuales no fueron tocadas a fondo pero igual es de interés observar cómo las concentraciones altas de este químico son indicadoras de Temperaturas más altas o bajas. Al igual vemos que las concentraciones de CO2 y O2 suelen ser representadas muy bien por la primera componente y apuntar hacia las mismas direcciones, grandes cantidades de observaciones estan relacionadas entre si y pueden que sean por la semejanzas entre el tipo de acciones por las cuales se generan estas emisiones y proporcionalmente hace que las dos suban de forma significativamente semejante.

Después al momento de hacer redes neuronales se decidió primero hacer una donde se indicará y entrenará al modelo para que hiciera clasificaciones entre variables y ver cuales tenian mas peso para detectar e indicar la calidad del aire, la cual no dejo tan interpretable los resultados por cuestiones de las capas y no poder crear mas entrenamiento con neuronas para que la red fuera mas clara y eficaz. Después se tuvo la idea de categorizar la variable de la calidad del aire en la que se clasifico en 5 categorias y fue mas interesante ver como ya era mas claro nuestro modelo al indicar que el PM2.5 afectaba a su calidad del aire y solia tener mucho peso al momento de ser el aire muy dañino, tambien se observo que en la categoría buena calidad del aire hay pesos muy dispersos y equilibrados entre los factores que pueden afectar y por último en la tabla de confusión se obtuvo cerca de un 99% de eficacia con los datos de prueba, indicando que la red hace un buen trabajo prediciendo.

REFERENCIAS

Yadav, M., Singh, N. K., Sahu, S. P., & Padhiyar, H. (2022). Investigations on air quality of a critically polluted industrial city using multivariate statistical methods: Way forward for future sustainability. Chemosphere, 291, 133024, recuperado de:. https://doi.org/10.1016/j.chemosphere.2021.133024

Platikanov, S., Terrado, M., Pay, M. T., Soret, A., & Tauler, R. (2022). Understanding temporal and spatial changes of O_3 or NO_2 concentrations combining multivariate data analysis methods and air quality transport models. Science of the Total Environment, 806, 150923. https://doi.org/10.1016/j.scitotenv.2021.150923

Gurjar, B.R., Butler, T.M., Lawrence, M.G., Lelieveld, J., 2008. Evaluation of emissions and air quality in megacities. Atmospheric Environment 42, 1593e1606.

Flemming, J., Stern, R., & Yamartino, R. J. (2005).A new air quality regime classification scheme for O3, NO2, SO2 and PM10 observations sites.Atmospheric Environment, 39(33), 6121–6129.https://doi.org/10.1016/j.atmosenv.2005.06.052

Wang, Y., Ying, Q., Hu, J., & Zhang, H. (2015).
Spatial and temporal variations of six criteria air pollutants in 31 provincial capital cities in China during 2013–2014.Environment International, 73, 413–422.https://doi.org/10.1016/j.envint.2014.08.016

Dominick, D., Juahir, H., Latif, M. T., Zain, S. M., & Aris, A. Z. (2012).Spatial assessment of air quality patterns in Malaysia using multivariate analysis.Atmospheric Environment, 60, 172–181.https://doi.org/10.1016/j.atmosenv.2012.06.021

Rojas-Bardález, A., & Guerra-Saldaña, M. (2022). *Nivel de contaminación del aire urbano por partículas suspendidas respirables (PM-10 y PM-2,5)*. Revista Amazónica de Ciencias Ambientales y Ecológicas, 1(2), e373. https://doi.org/10.51252/reacae.v1i2.373