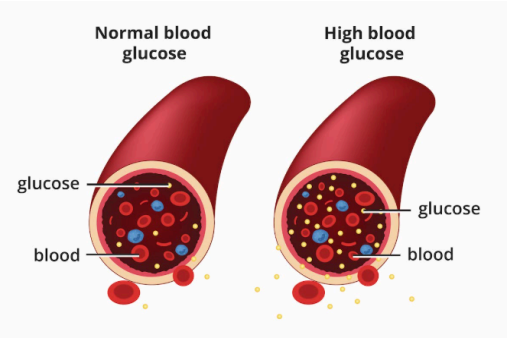
PROYECTO ESTADISTICA MULTIVARIADA

Fernando Garcia Gualito
Licenciatura en Matemáticas Aplicadas 7°1



PREGUNTA DE INVESTIGACIÓN:

¿Existen patrones que nos indiquen cuando una persona padece enfermedades como Retinopatía, Nefropatía y Neuropatía?

INTRODUCCIÓN

En este proyecto de investigación se analizan las enfermedades Retinopatía, Nefropatía y Neuropatía, en personas diabéticas considerando otras variables como sus signos vitales, tratamientos que llevan a cabo y enfermedades que podrían estar relacionadas con estos padecimientos. Primeramente, La diabetes Mellitus es un desorden metabólico que ocurre cuando nuestro cuerpo ya no produce suficiente insulina o ya no la utiliza de forma eficiente, esto provocando una falta de control en la glucosa en sangre. No se tiene cura, debe ser controlada y por tanto los diagnosticados tienen una alta tasa de mortalidad. Esta es la causa de complicaciones micro y macrovasculares , asi como neurológicas, lo que conduce a Retinopatía, Nefropatía y Neuropatía (Zaizar-Fregoso, 2023). “México tiene una prevalencia sustancialmente alta de trastornos metabólicos; el 75.2% de la población mexicana tiene obesidad o sobrepeso, el 10.3% padece DM y el 19.5% tiene dislipidemia” (Como se cita a Romero-Martínez en Fregoso 2023) .Después, saber cuales son estas 3 principales enfermedades que serán nuestros principales objetivos:
La Retinopatía es una enfermedad causada por daños en los vasos sanguíneos, siendo una complicación de la diabetes Mellitus muy común en el mundo pues a nivel global es diagnosticada en aproximadamente un tercio de la población. Por su parte la Nefropatía es la pérdida de las funciones renales la cual puede traer muchas complicaciones que pueden requerir de hemodiálisis o un trasplante de riñón.(Jianqing Li, et al.,2019) Por último la Neuropatía es considerada una polineuropatía sensoriomotora que se le es atribuido a cambios metabólicos y microvasculares en el cuerpo humano, que son resultados de enfermedades crónicas como hiperglucemia y covariables de riesgo cardiovascular.(L. Cardoso,2005). Es importante resaltar que esta enfermedad Neuropatía afecta a fibras nerviosas tales que tienen una similitud con las otras dos enfermedades anteriormente mencionadas por que las alteraciones microcirculatorias que se observa al padecerlas están asociadas a alteraciones a los nervios de igual forma.(Como se cita a Giannini C en L. Cardoso,2005).

MÉTODOS Y MARCO TEÓRICO:

·*Para este proyecto de investigación se utilizaran técnicas y métodos vistos en el curso de Estadística Multivariada, asi como el lenguaje de programación R que se plasmara el R-studio como ayuda para realizar las pruebas estadísticas; los cuales a partir de un dataset con mas de 30mil observaciones se explorará el conjunto multivariado y se obtendrán resultados con las herramientas que cumplan los supuestos que se solicitan para realizar las siguientes pruebas y métodos de análisis estadístico multivariado:*

· *El análisis de componentes principales es uno de los más usados en estadística multivariante ya que ayuda a reducir dimensiones, eliminando la mínima variabilidad de los datos originales a coste de indicadores que no son significativos en el análisis.(Azid et al., 2014). Dada la siguiente ecuación* $Yi = ai1x1 + ai2x2 + \cdots + aipx$ *para el componente i de un conjunto de p variables. Suponiendo cada punto como como elementos dij descompuesto como la suma de varios componentes cada uno definido como productos de puntuaciones(xi) y cargas(yi).(Playikanov2022)*

· *Por su parte el análisis factorial es una técnica de interdependencia que utiliza a todas las variables para crear nuevas variables no observadas antes, esto a partir de la correlación entre cada variable original. Al momento de hablar de las correlaciones entre variables hay varias complicaciones, ya que al estar algún par de variables altamente relacionadas es probable que no compartan variabilidad con las demás variables y por ende con factores comunes, por lo tanto afecta la estabilidad del análisis. "La medida de adecuación muestral de Kaiser-Meyer-Olkin(KMO) es un índice que compara la magnitud de los coeficientes de correlación observados con la magnitud de los coeficientes de correlación parcial"(Guerra N.) Este índice se calcula de las correlaciones simples y parciales para cada variable i, j, rij y rijm respectivamente. Puesto que la segunda debe ser pequeña (término del denominador) obtendremos un KMO cercano a 1, lo que indica que los datos forman estructuras de factores; Por caso contrario, si el valor de medida de adecuación muestral es bajo no es apto para un análisis factorial (casos menores a 0.6).(Guerra N.)*

$$KMO = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} r_{ij.m}^2}$$

· *MANOVA es una técnica que se utiliza para probar y cuantificar el efecto entre variables, es un análisis de varianza multivariada como lo indican sus siglas en inglés, a diferencia del ANOVA se tienen 2 o más variables dependientes. Solo que puede haber complicaciones si en un MANOVA se consideran variable por variable y se hacen ANOVAs ya que algunos valores podrían ser significativos por separado y en conjunto estar en la region de no rechazo.Cuando hay múltiples variables dependientes presentes, realizar un MANOVA es beneficioso porque reduce la probabilidad de error de tipo I (Fish, 1988; Haase y Ellis, 1987; Huberty y Morris, 1989). El manova puede probar diferencias entre variables subyacentes*

del conjunto original. Y utilizaremos el estadístico Lambda de wilks que discrimina grupos entre las observaciones, si se tiene valores bajos de este estadístico hay buena separación entre medias, caso contrario, si hay un valor alto entonces no hay diferencias significativas.(Warne, R., 2014)

- *Por su parte, el análisis de conglomerados se dividió en dos partes, puramente con variables continuas trabajando con la técnica de k-means; En la cual consiste de elegir el número de grupos en el que se dividirá y basándose en la distancia euclidiana formar centroides, en el proceso se itera hasta que la estabilidad de los grupos sea la mejor.(Abiodun M.) Se utilizó el método del codo que trata de minimizar las distancias intra cluster utilizando la suma de distancias cuadradas (WSS) que entre mas pequeña sea, más compacto será el cluster, esta distancia también explica la varianza tomando como foco el centroide.(Alonso 2025). En el cual las gráficas que se presentan, están compuestas del eje horizontal como el número de clusters, y el vertical como WSS de forma que al momento de tener una caída repentina y luego estabilizarse, ese k sera nuestro número "óptimo" de clusters.*

El método de la silueta esta basado en cuan similar es un objeto perteneciente a un cluster de los demas, utilizando distancias para compararse con objetos de otros grupos y del suyo. La silueta para una observación determinada i es una combinación de la cohesión a(i) y b(i). La silueta para el individuo i está definida como:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

$$a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, i \neq j} d(i,j)$$

$$b(i) = \min_{k \neq i} \frac{1}{|C_k|} \sum_{j \in C_k} d(i,j)$$

Es fácil demostrar que s(i) se encuentra entre-1y+1.Entre Más Cercano Uno Indica que el individuo i está bien ubicado en su conglomerado. Es decir, la clasificación actual en Ci es mejor que con los grupos vecinos. Por otro lado, un valor cerca a cero o negativo implica que es posible que el individuo fue mal clasificado en su clúster Ci.(Alonso, 2025)

- *También se utilizó la regresión logística para analizar probabilidades dependiendo de los grupos donde se encontrarán las personas. La regresión logística es una herramienta de análisis multivariado que tiene por fines explicar e incluso predecir, con variables de respuesta o dependientes dicotómicas, y variables independientes continuas o categóricas.(SEQC). Así como en un modelo de regresión lineal múltiple, tendremos una ecuación de coeficientes predictores para la variable dependiente.*

$$logit = \beta_0 + \beta_1 HTA + \beta_2 DM + \beta_3 HTA\,DM + \ldots$$ *(SEQC)*

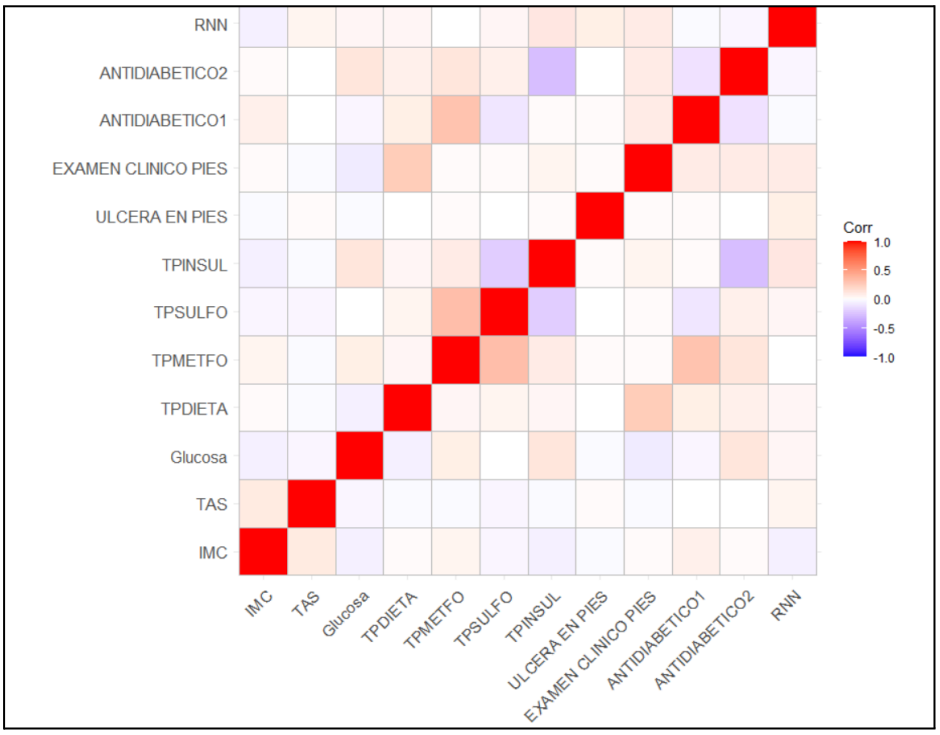
"Para la estimación de los coeficientes del modelo y de sus errores estándar se recurre al cálculo de estimaciones de máxima verosimilitud, es decir, estimaciones que hagan máxima la probabilidad de obtener los valores de la variable dependiente Y proporcionados por los datos de nuestra muestra."(SEQC)

Para este modelo de regresión se utilizó odds ratios como los coeficientes del mismo, "Estos valores indican cuánto se modifican las probabilidades por unidad de cambio en las variables x."(SEQC)

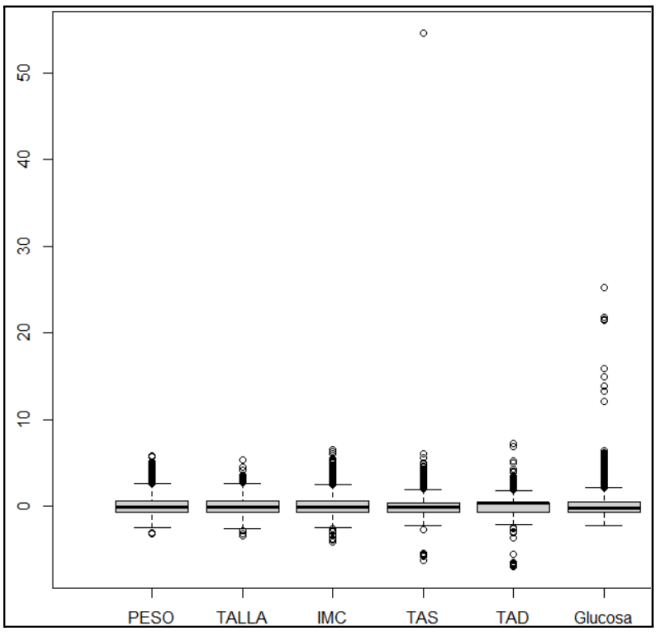
·Las redes neuronales artificiales son una herramienta con la que se aprenden procesos con base a funciones cerebrales humanas y que tienen como objetivo la predicción de diferentes clases.(Chiñas, et.al.2013) Está basado en un conjunto de pilares de activación a los cuales llamaremos nodos. "Pueden ser utilizadas para resolver problemas de reconocimiento de patrones tanto supervisados como no supervisados" (Soler, 2007)

DESARROLLO:

Para algunos de los métodos que se aplican a continuación se eligió excluir peso y talla por su redundancia con la variable IMC.



Así como se eliminaron outliers (casos atípicos) de las variables con valores continuos para limpiar los datos que no son posibles clínicamente en cada unidad de medida de IMC, TAS, TAD, Glucosa y Talla.

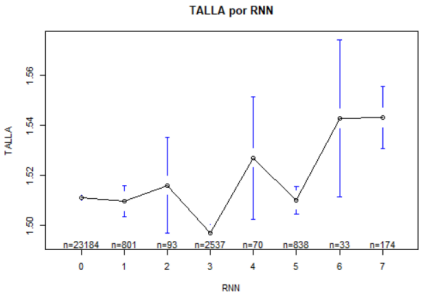


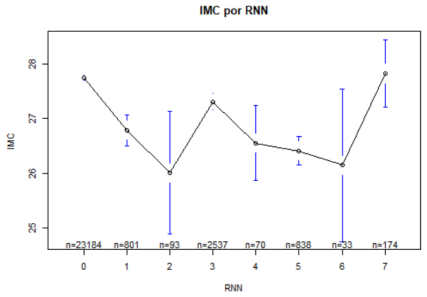
MANOVA

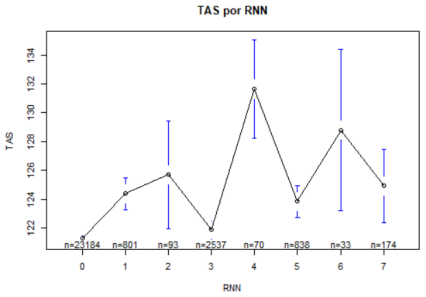
Comencemos con un Análisis de Varianza multivariada(MANOVA) de una via para nuestra variable objetivo RNN, en la cual observaremos si hay diferencias significativas entre la variabilidad de los individuos en las variables TALLA,IMC, TAS, TAD y GLUCOSA dependiendo de que categoría se encuentren en la variable RNN.
La función manova() de R, junto con la prueba de wilks en la que la Ho: No existen diferencias significativas entre las medias de cada variable por categoría de RNN, nos arrojo los siguientes resultados:

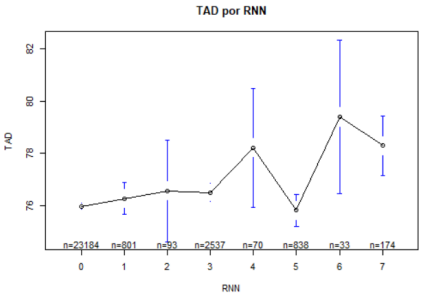
```
> summary(modelo, test = "Wilks")
             Df   Wilks approx F num Df den Df    Pr(>F)
RNN           1 0.99343   36.698      5  27724 < 2.2e-16 ***
Residuals 27728
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

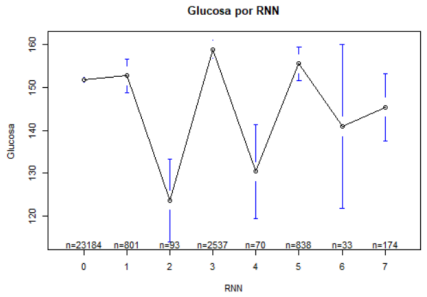
En la que observamos por el p-value que rechazamos la hipótesis nula, es decir, existen diferencias significativas entre las medias y variabilidad de cada categoría de RNN, y las variables de respuesta TALLA, IMC, TAS, TAD y Glucosa.
Para observar más claro, aquí tenemos el caso univariado por cada una de las variables por RNN, donde observamos claramente las medias variando significativamente por categoría:







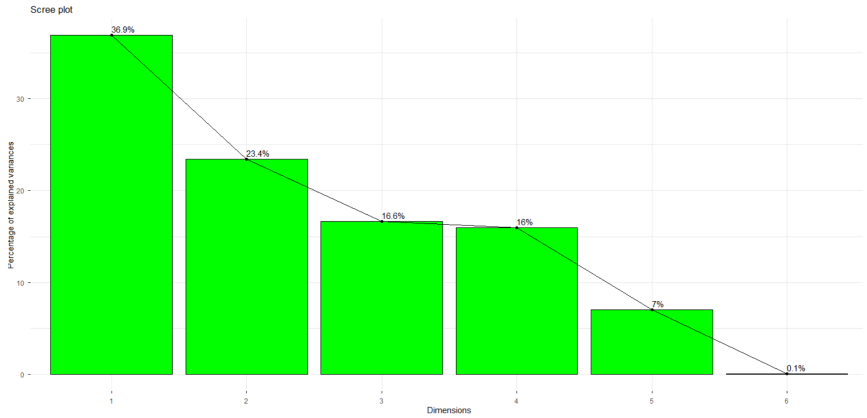




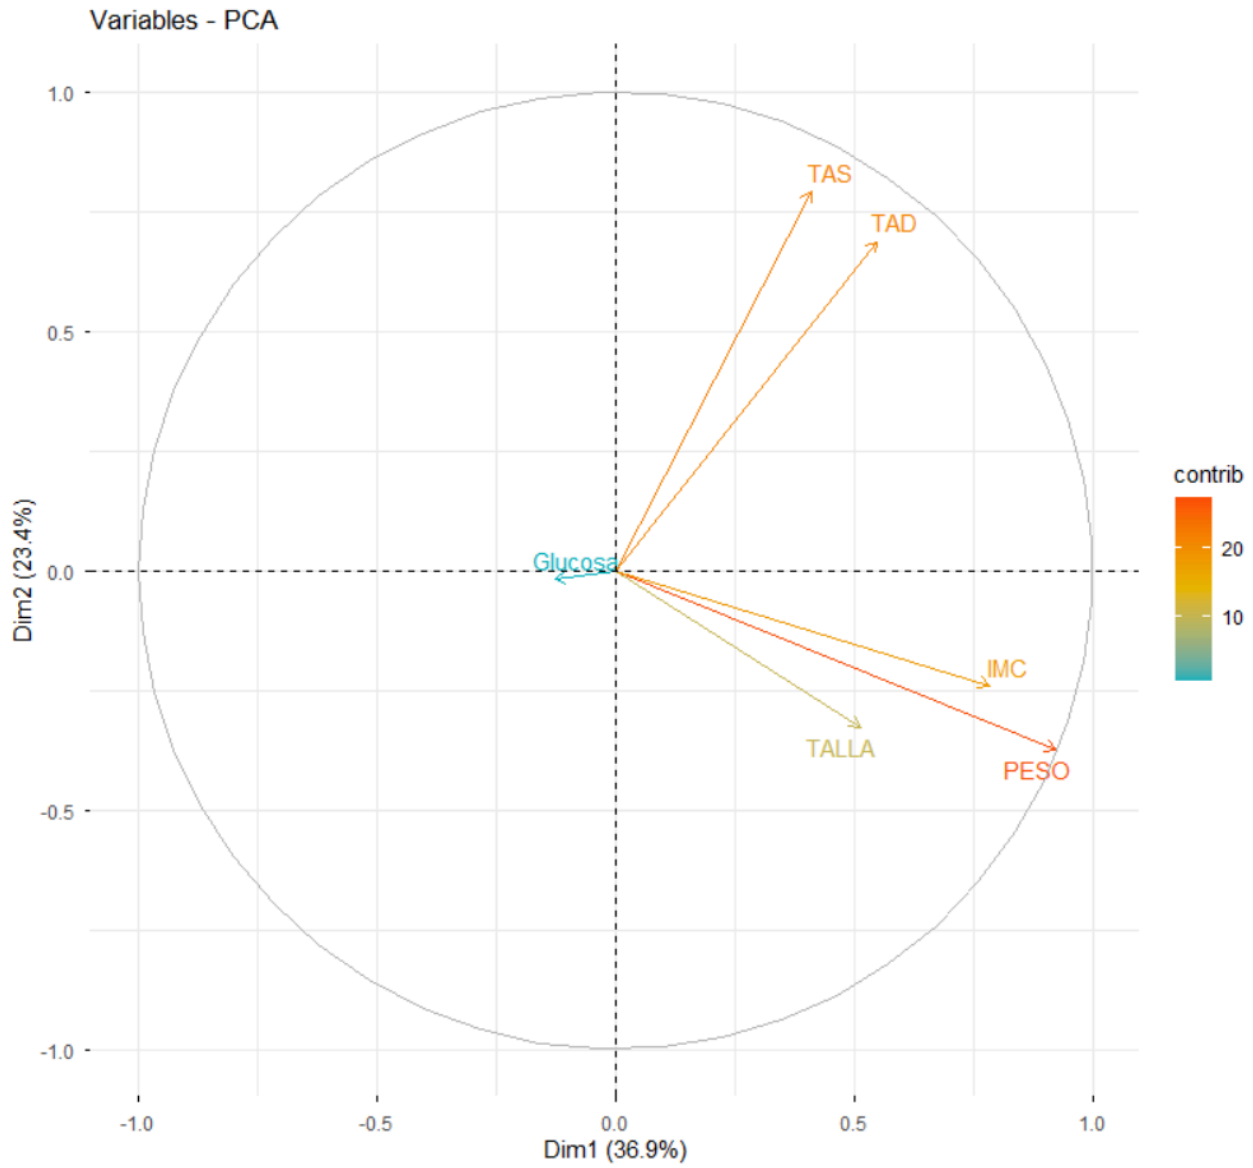
ANÁLISIS DE COMPONENTES PRINCIPALES

Vamos a considerar nuevamente solo las variables PESO,TALLA, IMC,TAS, TAD y Glucosa:

```
> datosacp = princomp(matrizcorr)
> summary(datosacp)
Importance of components:
                          Comp.1    Comp.2    Comp.3     Comp.4     Comp.5
Standard deviation     0.6265284 0.5369519 0.3915478 0.17622625 0.06575953
Proportion of Variance 0.4514291 0.3315727 0.1763102 0.03571488 0.00497308
Cumulative Proportion  0.4514291 0.7830018 0.9593120 0.99502692 1.00000000
                          Comp.6
Standard deviation             0
Proportion of Variance         0
Cumulative Proportion          1
```



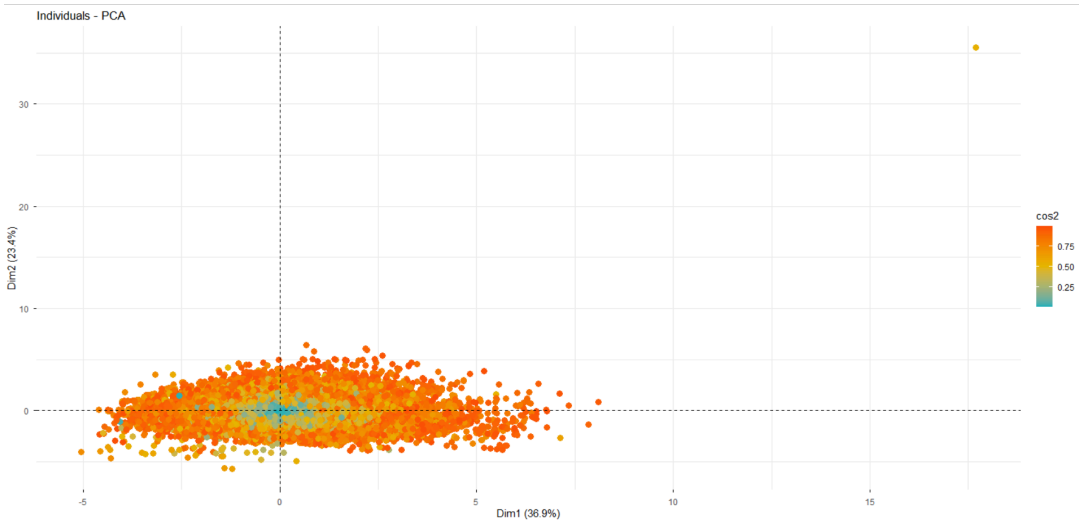
En donde observamos con dos distintos métodos de R, como lo son princomp() y PCA(), como las dos primeras componentes principales explican el 78.3% y 60.3% respectivamente de la varianza de los datos.



Observamos por una parte como TAS y TAD (Presiones Arteriales Sistólica y Diastólica) tienen gran carga en el componente principal 2, mientras que las variables relacionadas con el IMC (Peso y Talla) y el propio IMC representan más a los datos en la primera Componente Principal. Por último la variable glucosa es la que menos aporte de varianza tiene en estas 2 primeras componentes principales.

```
> res$var$coord[, 1:2]
             Dim.1      Dim.2
PESO     0.9231697 -0.3753936
TALLA    0.5132681 -0.3269037
IMC      0.7834794 -0.2403430
TAS      0.4091789  0.7920529
TAD      0.5474522  0.6874844
Glucosa -0.1258458 -0.0173940
```

En la siguiente gráfica de individuos podemos visualizarlos respecto a las 2 dimensiones de nuestras componentes, con la cual más adelante se tendrá de apoyo para realizar análisis factorial y de conglomerados.



ANÁLISIS FACTORIAL

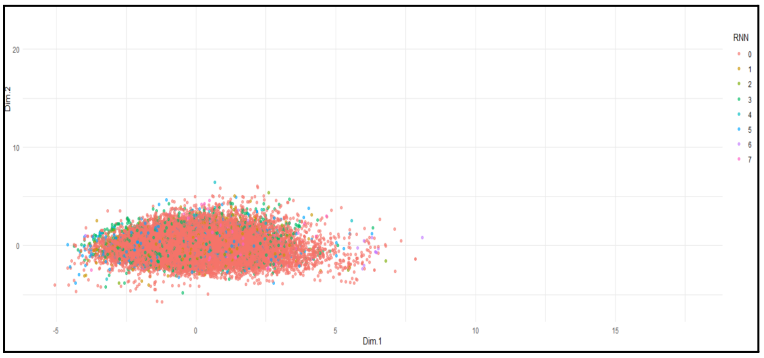
Realizando un análisis de Factores basándonos primero en la prueba de Kaiser-Meyer-Olkin tenemos el siguiente resultado:
MSA=0.33<0.7

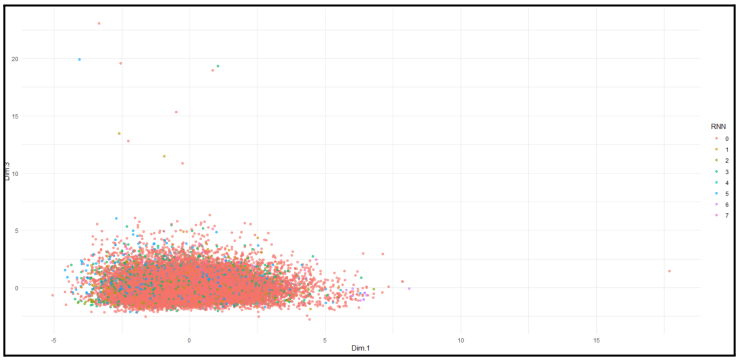
```
Kaiser-Meyer-Olkin factor adequacy
Call: KMO(r = Mcr)
Overall MSA =  0.33
MSA for each item =
             PESO            TALLA              IMC              TAS              TAD          Glucosa        TPDIETA         TPMETFO         TPSULFO
             0.36             0.17             0.26             0.51             0.56             0.45             0.54            0.36            0.35
         TPINSUL ULCERA EN PIES EXAMEN CLINICO PIES     ANTIDIABETICO1     ANTIDIABETICO2              RNN
             0.34             0.55             0.49             0.33             0.37             0.56
```

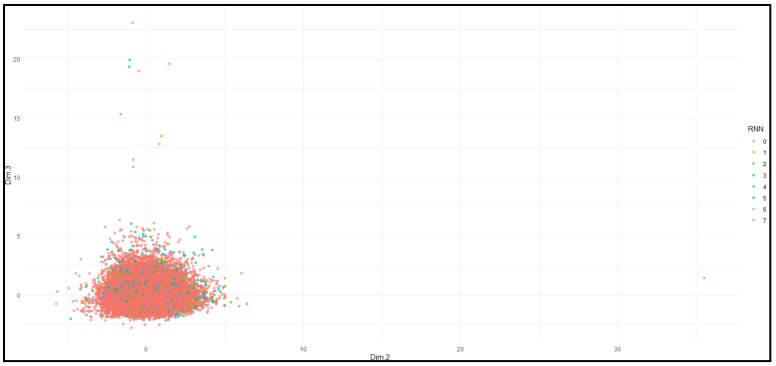
No tenemos la suficiente varianza común entre variables para poder realizar un buen análisis factorial. Incluso aunque tratamos de seleccionar las variables con MSA más altos, se obtiene un overall MSA=0.5 que no es bueno para análisis factorial, y aunque lo realizáramos no nos diría cosas importantes.

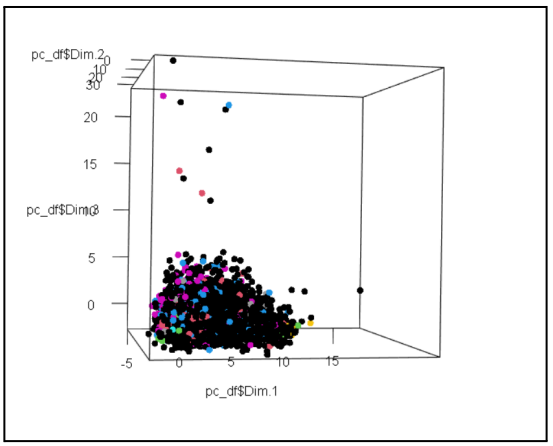
CLUSTERING (ANÁLISIS DE CONGLOMERADOS)

Vamos a utilizar de apoyo el Análisis de Componentes principales para poder explicar de forma más fácil las variables continuas que tenemos y de tal forma tratar de detectar clusters de forma visual. A continuación se observan gráficas de los individuos en las componentes, 1 y 2, 1 y 3, 2 y 3. Paralelamente se clasificaron dependiendo sus valores en la variable RNN con un color distinto. Incluso en la cuarta figura podemos observar un plot 3D en las primeras 3 componentes principales. Notemos que los individuos con 0 en la variable RNN estan opacando y sufriendo aa todos los demás; Esto por la predominancia de pacientes que afirmaron no tener ningún padecimiento (n=25576) casi un 84% de la muestra total.

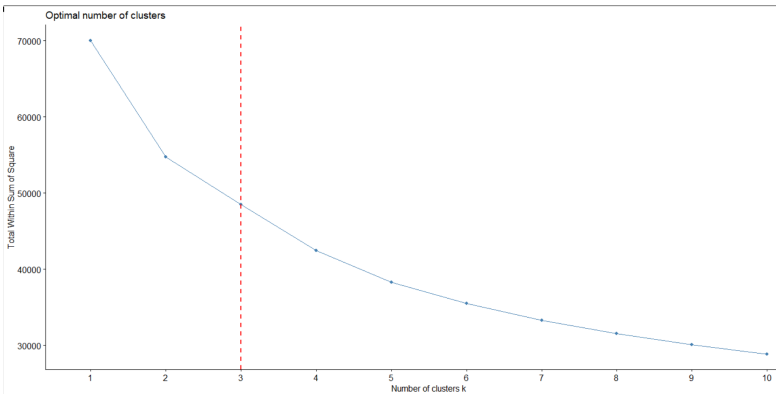




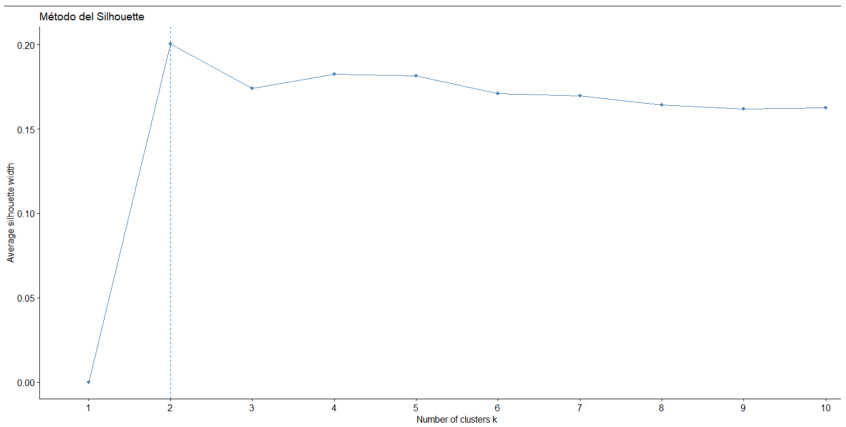




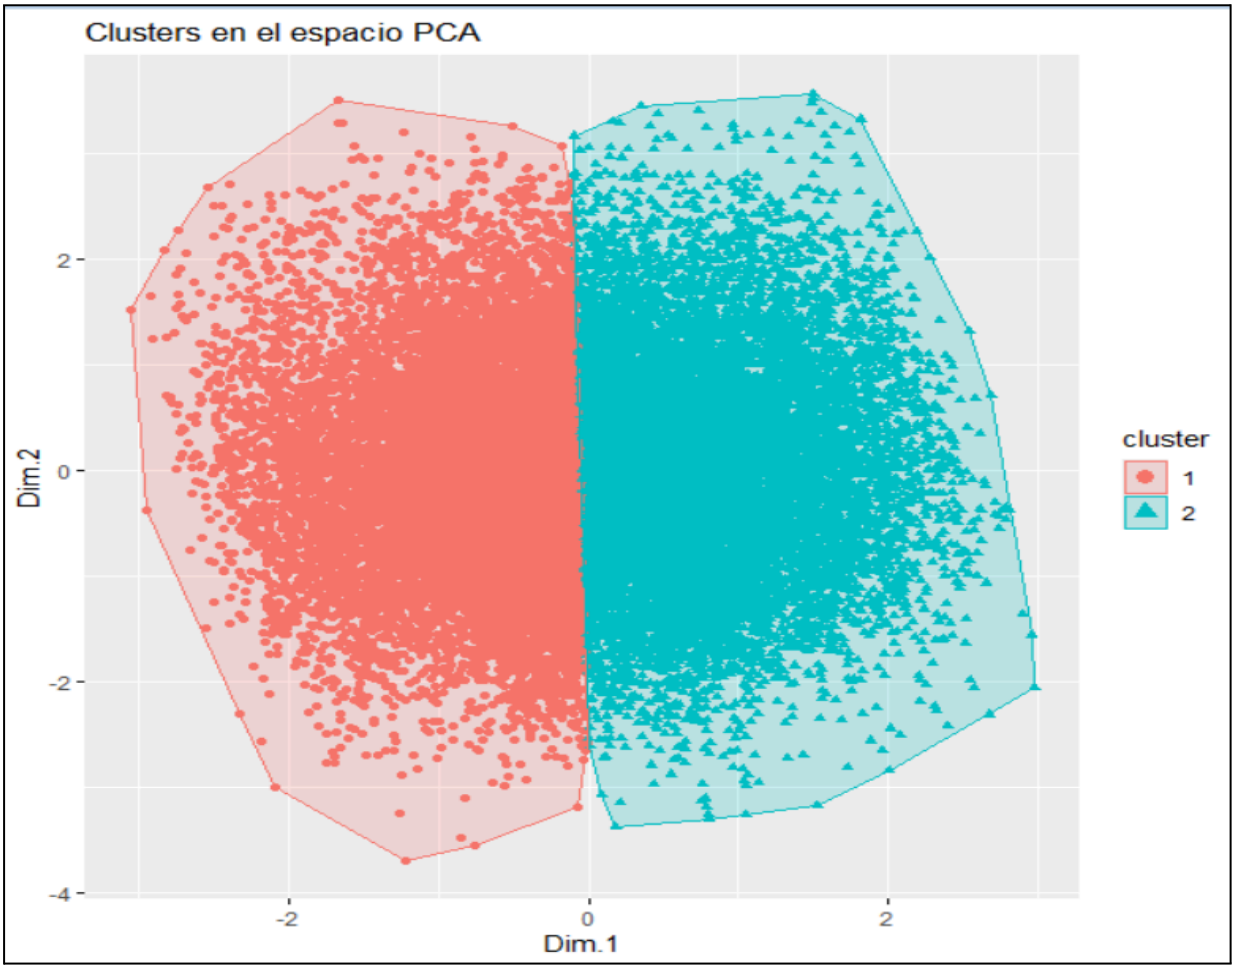
Métodos para decidir número de clusters: Regla del codo y método de la silueta.



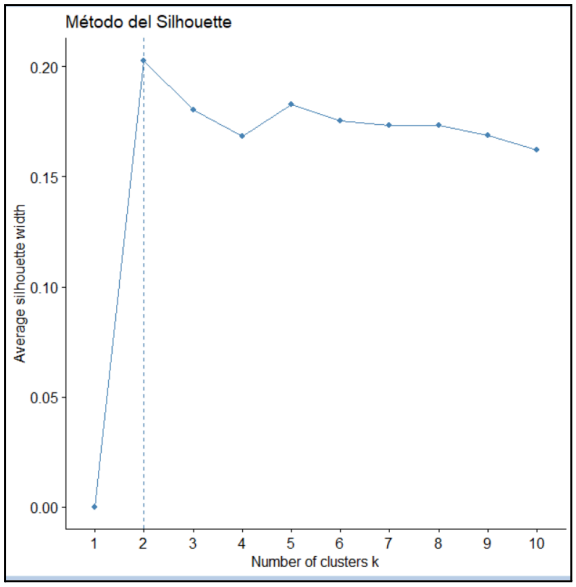
En este gráfico observamos el codo con un criterio visual en el número k=3, pero bien podría ser en k=2.

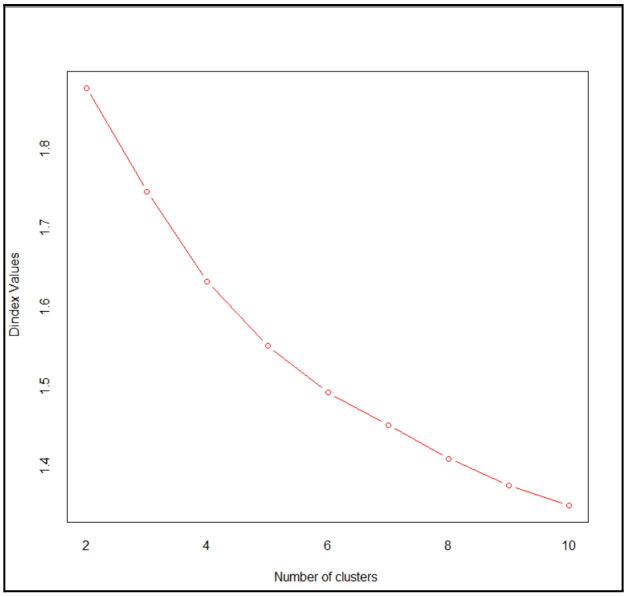


En este con el método de la silueta identificando el pico más alto tenemos que el número indicado de clusters en k=2



Por un momento vamos a remover los individuos que tienen valores de 0 en la variable RNN, así quedándonos con 4611 observaciones, esto ya después de quitar valores atípicos también.






```
**********************************************************************
* Among all indices:
* 7 proposed 2 as the best number of clusters
* 5 proposed 3 as the best number of clusters
* 4 proposed 4 as the best number of clusters
* 4 proposed 5 as the best number of clusters
* 2 proposed 8 as the best number of clusters
* 1 proposed 10 as the best number of clusters

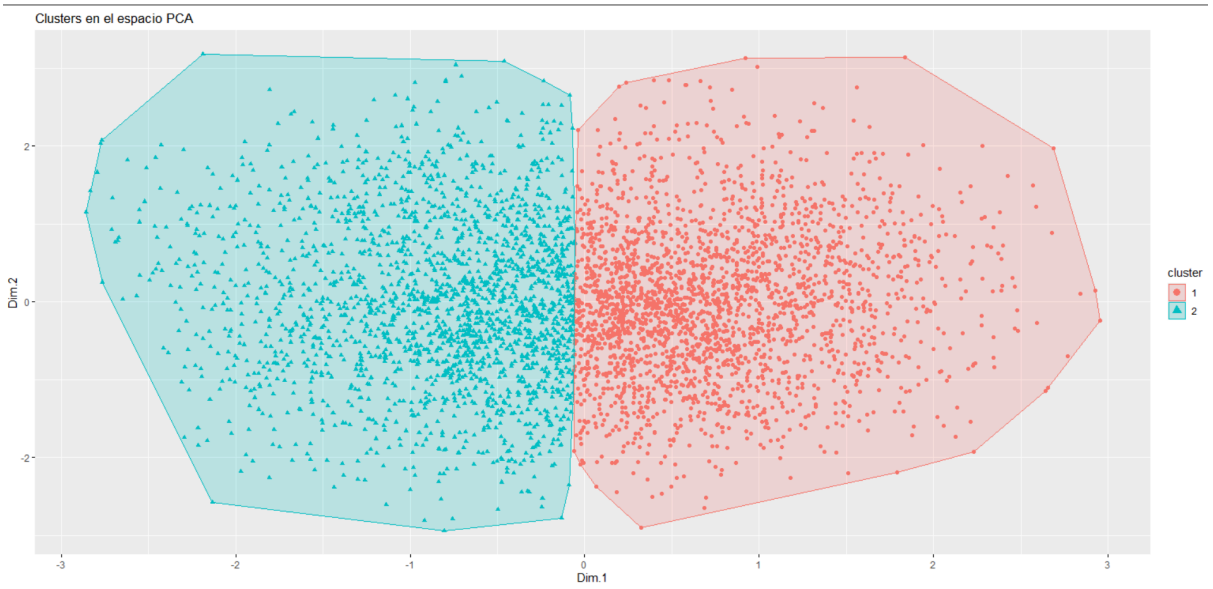
                   ***** Conclusion *****

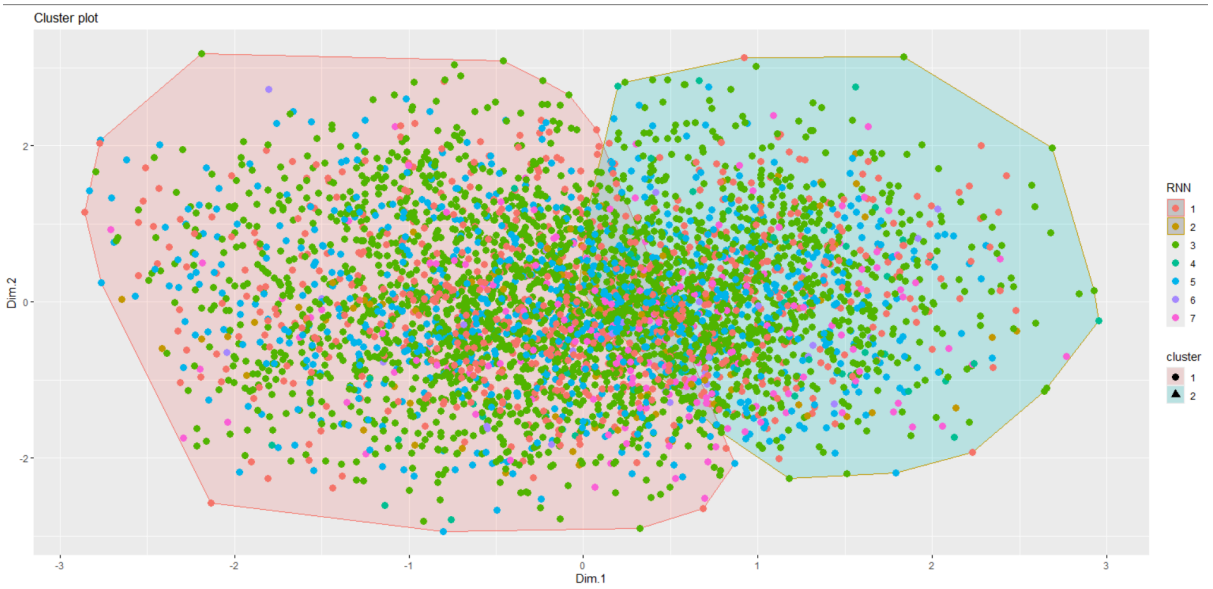
* According to the majority rule, the best number of clusters is  2

**********************************************************************
```

Al igual que con los 27 mil observaciones originales, en este caso se eligió 2 como el número de clusters óptimo.

Gráficos de los clusters en las dos primeras componentes principales (Individuos que tienen algún padecimiento RNN)





En la siguiente tabla se observa el número de individuos pertenecientes a cada uno de los 2 clusters en los cuales por método de k-means se dividió el conjunto de datos.

	1	2	3	4	5	6	7	Sum
1	457	50	1469	27	474	14	86	2577
2	343	42	1092	49	388	19	101	2034
Sum	800	92	2561	76	862	33	187	4611

```
          1         2         3         4         5         6         7
1 0.5712500 0.5434783 0.5736041 0.3552632 0.5498840 0.4242424 0.4598930
2 0.4287500 0.4565217 0.4263959 0.6447368 0.4501160 0.5757576 0.5401070
```

coeficiente de jaccard para 2 y 3 grupos:

```
Number of resampling runs:  100

Number of clusters found in data:  2

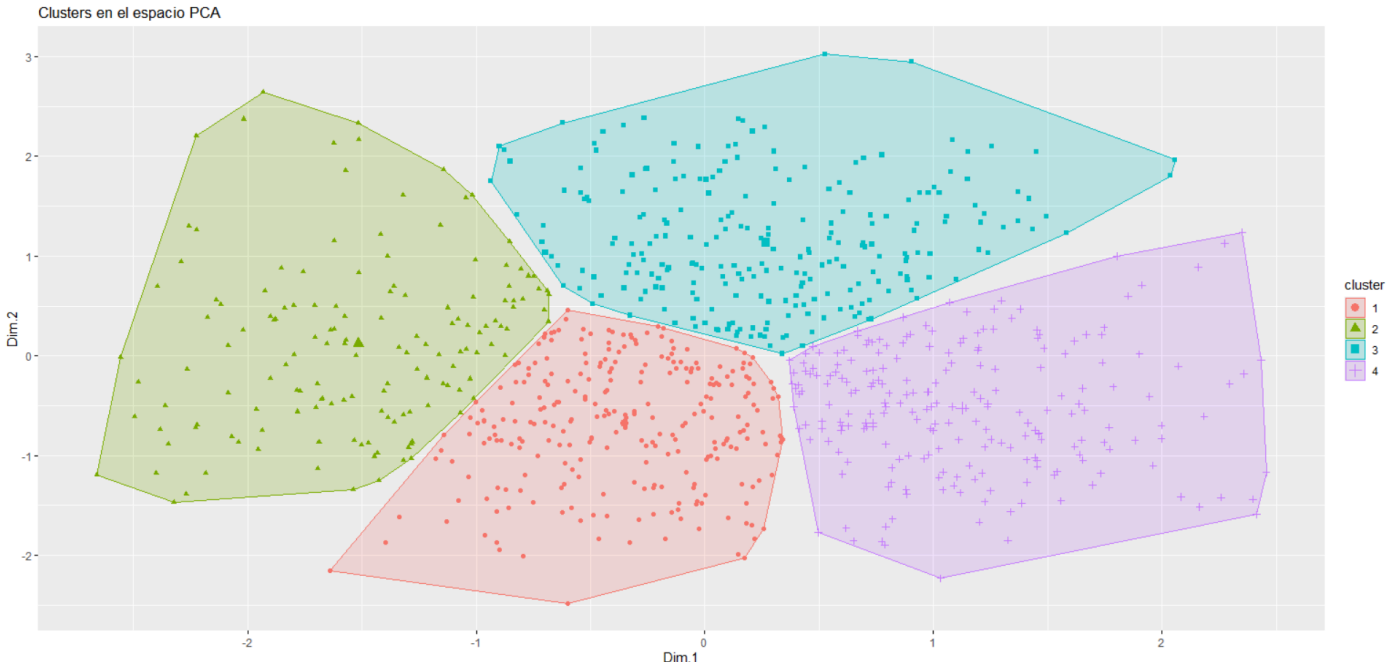
 Clusterwise Jaccard jittering mean:
[1] 0.9993213 0.9992802
dissolved:
[1] 0 0
recovered:
[1] 100 100
 Clusterwise Jaccard bootstrap (omitting multiple points) mean:
[1] 0.9895542 0.9889187
dissolved:
[1] 0 0
recovered:
[1] 100 100
```

```
Number of resampling runs:  100

Number of clusters found in data:  3

 Clusterwise Jaccard jittering mean:
[1] 0.4115829 0.6770836 0.6754132
dissolved:
[1] 76  1  1
recovered:
[1] 24 24 24
 Clusterwise Jaccard bootstrap (omitting multiple points) mean:
[1] 0.3954498 0.6657432 0.6646442
dissolved:
[1] 77  2  1
recovered:
[1] 22 23 23
```

Análisis de conglomerados desde la perspectiva de las personas que tienen Retinopatía y Nefropatía:




```
*****************************************************************
* Among all indices:
* 7 proposed 2 as the best number of clusters
* 4 proposed 3 as the best number of clusters
* 4 proposed 4 as the best number of clusters
* 3 proposed 5 as the best number of clusters
* 2 proposed 9 as the best number of clusters
* 3 proposed 10 as the best number of clusters

                 ***** Conclusion *****

* According to the majority rule, the best number of clusters is  2


*****************************************************************
```

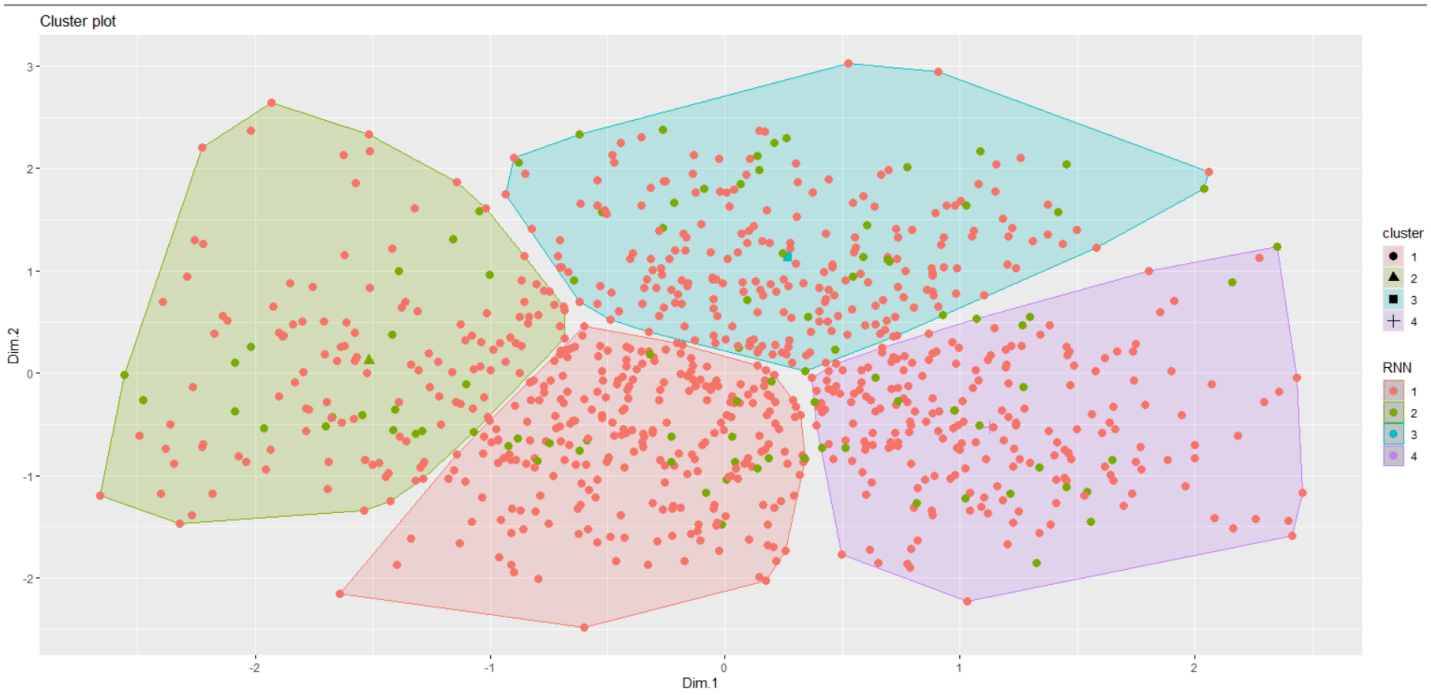
Haciendo una prueba del coeficiente de jaccard para 4 cluster tenemos:

```
Number of clusters found in data:  4

 Clusterwise Jaccard jittering mean:
[1] 0.9377972 0.9565119 0.9537117 0.9405963
dissolved:
[1] 1 5 1 6
recovered:
[1] 97 95 99 94
 Clusterwise Jaccard bootstrap (omitting multiple points) mean:
[1] 0.8259738 0.8071614 0.8266968 0.7832566
dissolved:
[1]  4 15  8 15
recovered:
[1] 79 80 85 71
```

Donde observamos que está en un intervalo muy aceptable arriba del 0.7, también la disolución de los grupos es válida.

Vamos a hacer un pequeño análisis exploratorio tratando de detectar características de pacientes en conjunto y si hay algún impacto en las enfermedades que padecen (Retinopatía y Nefropatía)



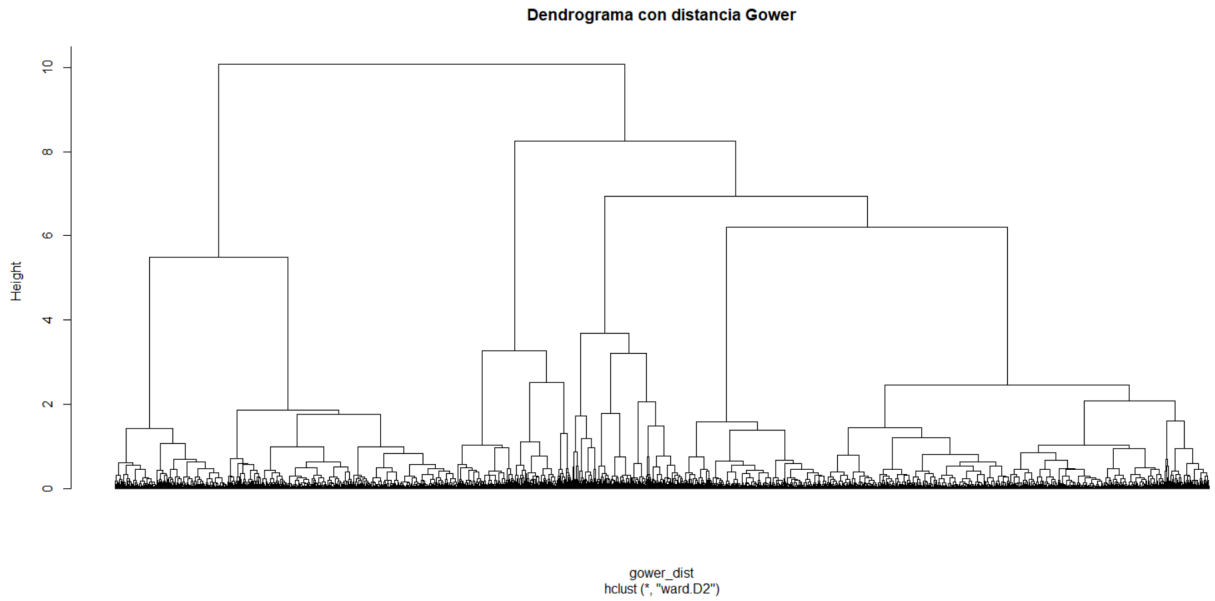
En donde observamos cómo se distribuyen los 2 valores de RNN en los 4 clusters. En donde los únicos "relevantes" es que existe menor proporción de personas con Retinopatía en el cluster 2. Mientras que en el cluster 3 se presentan más personas con Nefropatía.

	1	2	Sum
1	250	19	269
2	127	20	147
3	216	31	247
4	201	22	223
Sum	794	92	886

	1	2
1	0.3148615	0.2065217
2	0.1599496	0.2173913
3	0.2720403	0.3369565
4	0.2531486	0.2391304

Método Jerárquicos: Dendograma (Método de Ward)

Se utilizó la distancia Gower para hacer una combinación entre las variables continuas y las variables categóricas, y asi no perder información que clínicamente es muy importante. Como tal el método ward hizo n clusters iniciales de los cuales partió y fue agrupando minimizando el incremento en la suma de cuadrados de diferencias, de cada cluster entre el individuo y su centroide. Asi hasta concluir con clusters más generales como lo vemos en la siguiente dendograma:



Donde lo mas correcto y basándonos en la mayor distancia entre clusters es quedarnos con 2, justo como lo indicaba k-means igual.

Regresión Logística:

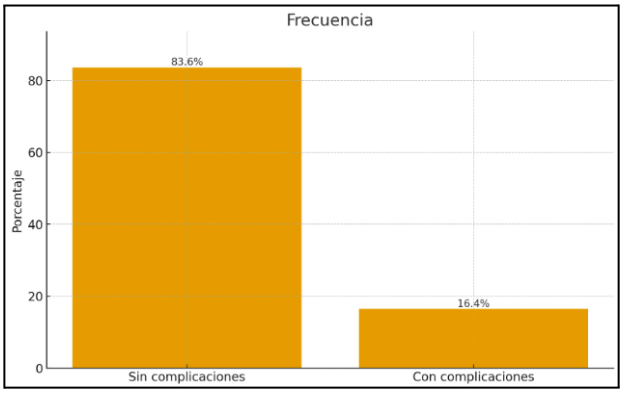
Vamos a considerar la variable RNN como dicotómica, de 2 formas distintas:

1. *Los casos 0 (No existe algún padecimiento) y casos 1,2,3,4,5,6,7 (existe alguna complicación o más)*
2. *Los casos 0 (No existe algún padecimiento) y los casos 3 (pacientes con Neuropatía)*

1.Tenemos que 23184 de los individuos no tienen ningún padecimiento y 4546 individuos tienen al menos un padecimiento como Retinopatía, Neuropatía o Nefropatía.

	Sin_complicaciones	Con_complicaciones
0	23184	0
1	0	801
2	0	93
3	0	2537
4	0	70
5	0	838
6	0	33
7	0	174

23184	4546



-Seleccionaremos para una regresión logística binomial las variables que representan el seguimiento de tratamientos que siguen las personas: TPDIETA, TPMETFO, TPSOLFU, TPINSUL. Realizando la regresión con la función glm() de R, tenemos los siguientes resultados que muestran los coeficientes de cada variable para el modelo de regresión y también los errores estándar. También se muestran estadísticos z y p-values (muy pequeños)

```
Call:
glm(formula = RNN_bin ~ TPDIETA + TPMETFO + TPSULFO + TPINSUL,
    family = binomial, data = datos_sin_outliers)

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.64285    0.14956 -17.670  < 2e-16 ***
TPDIETA      0.77481    0.14996   5.167 2.38e-07 ***
TPMETFO     -0.14825    0.03532  -4.197 2.70e-05 ***
TPSULFO      0.47839    0.03620  13.216  < 2e-16 ***
TPINSUL      0.86753    0.04812  18.028  < 2e-16 ***
```

En esta tabla observamos los odds ratios o razones de momios que son probabilidades que vamos a comparar con personas que llevan una tipo de tratamiento y las que no. Y cómo influye en los diagnósticos de enfermedades de RNN.

	OR	2.5 %	97.5 %
(Intercept)	0.07115812	0.05240393	0.09435738
TPDIETA	2.17018996	1.63518622	2.94891582
TPMETFO	0.86221915	0.80447997	0.92394539
TPSULFO	1.61347467	1.50297498	1.73212303
TPINSUL	2.38103081	2.16596936	2.61567141

Se está haciendo un modelo que compara en conjunto los 4 tratamientos de los que tenemos información acerca de los pacientes, ninguno presentó un intervalo de confianza alrededor de 1, es decir, tenemos que las variables están asociadas con las personas que tienen padecimientos de RNN.
-Las personas que tienen un tratamiento dietético tienen 2.17 veces mas probabilidad de padecer al menos una enfermedad (RNN)
-Las personas que llevan tratamiento de metformina tienen aproximadamente 14% menos probabilidad de padecer.
-Los individuos con tratamientos de Sulfonilureas e Insulina tienen 1.6 y 2.38 respectivamente mas posibilidades de que padezcan al menos una enfermedad.

Es decir, nuestro modelo está indicando asociación de que tan probable es que una persona que lleva justamente este tipo de tratamientos pueda o no tener al menos una enfermedad de Retinopatía, Nefropatía o Neuropatía.

Consideremos ahora las variables de los signos vitales de los individuos, como lo son IMC, TAS, TAD y Glucosa:

Coefficients:

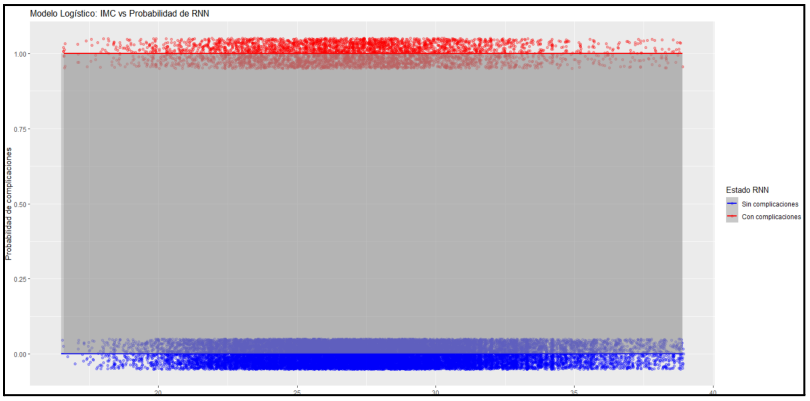
	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-1.567103	0.187849	-8.342	< 2e-16	***
IMC	-0.050849	0.004330	-11.743	< 2e-16	***
TAS	0.007769	0.001260	6.166	7.0e-10	***
TAD	0.002648	0.002300	1.152	0.249	
Glucosa	0.001168	0.000299	3.906	9.4e-05	***

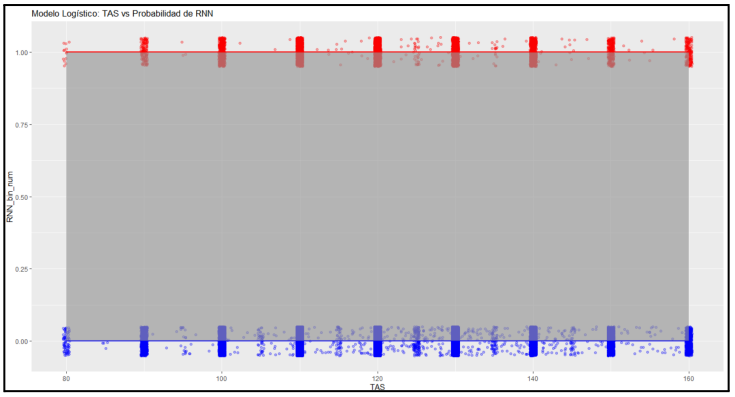
	OR	2.5 %	97.5 %
(Intercept)	0.2086488	0.1443295	0.3014136
IMC	0.9504219	0.9423752	0.9585079
TAS	1.0077994	1.0053105	1.0102884
TAD	1.0026520	0.9981460	1.0071844
Glucosa	1.0011684	1.0005805	1.0017540

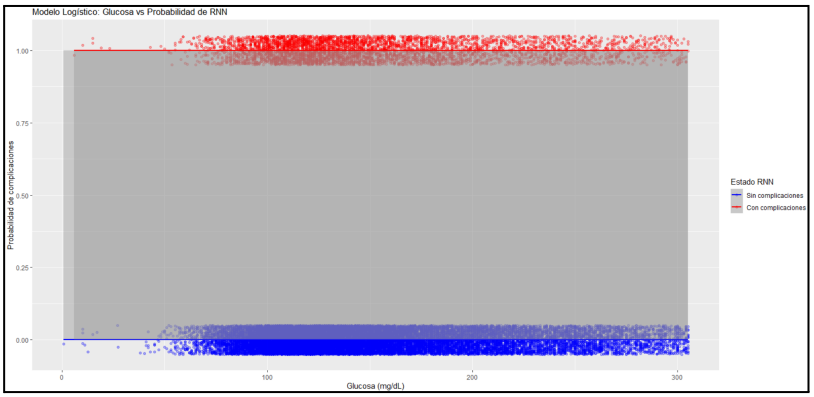
Podemos ver que TAD tiene un intervalo de confianza del 95% en el que cruza al uno por lo que no es significante para las predicciones.

Por su parte el IMC presentó disminuir un 5% de probabilidad por cada unidad de IMC ($\frac{kg}{m^2}$) lo que representa que si una persona presenta 5 unidades de IMC más, el modelo indica 23% menos probabilidades de padecer algún tipo de combinación de RNN.

Así mismo el TAS presentó aumentar un 8.3% de probabilidad por cada 10 mmHg.
Y la glucosa un 6% por cada 50 mg/dL más de glucosa en sangre.







2.Comparemos las personas que tienen Neuropatía vs las que no lo padecen, para eso se incluyó los valores de RNN, 3,5,6 y 7 que son las personas que padecen Neuropatía. Haremos un modelo de regresión logística con variables independientes: ÚLCERA EN PIES y EXAMEN CLÍNICO PIES.

```
glm(formula = RNN_bin ~ `ULCERA EN PIES` + `EXAMEN CLINICO PIES`,
    family = binomial, data = datos_sin_outliers)

Coefficients:
                     Estimate Std. Error z value Pr(>|z|)
(Intercept)          -3.10727    0.09718  -31.97   <2e-16 ***
`ULCERA EN PIES`      2.21522    0.19274   11.49   <2e-16 ***
`EXAMEN CLINICO PIES` 1.30312    0.09889   13.18   <2e-16 ***
```

```
                              OR      2.5 %      97.5 %
(Intercept)           0.04472286 0.03675543  0.05382081
`ULCERA EN PIES`      9.16346656 6.30036899 13.44022141
`EXAMEN CLINICO PIES` 3.68075045 3.04770810  4.49278829
```

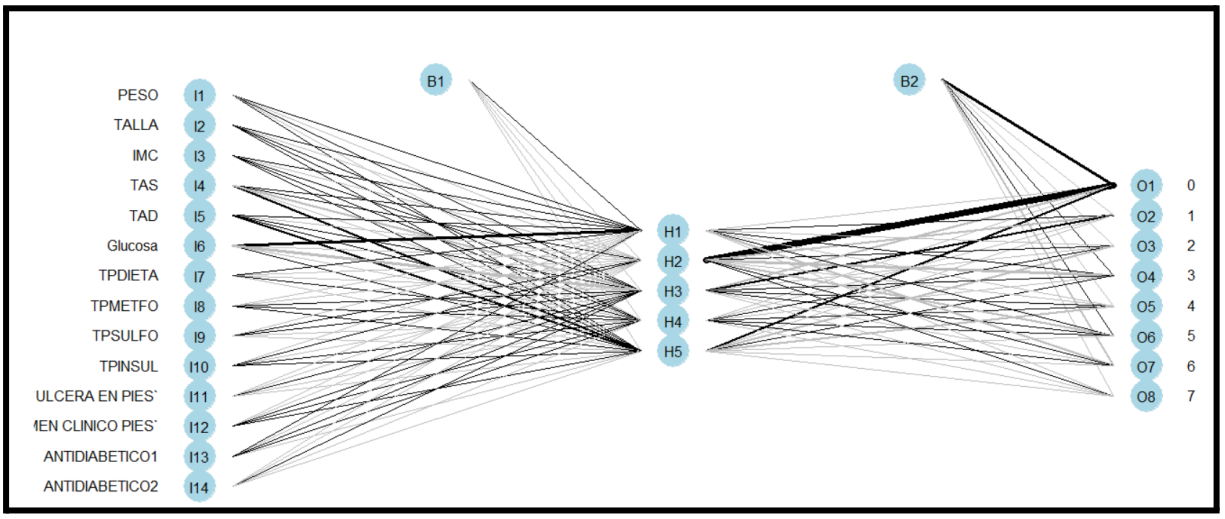
En el que podemos ver con claridad como el hecho de tener úlcera en pies está asociado con padecer Neuropatía considerablemente, contribuyendo en ser 9.1 veces más probable padecer Neuropatía si tienes úlcera en pies.
Al igual que si una persona se hizo un examen clínico en pies, tiene 3.7 veces más probabilidad de que estemos frente a una persona que tenga Neuropatía.

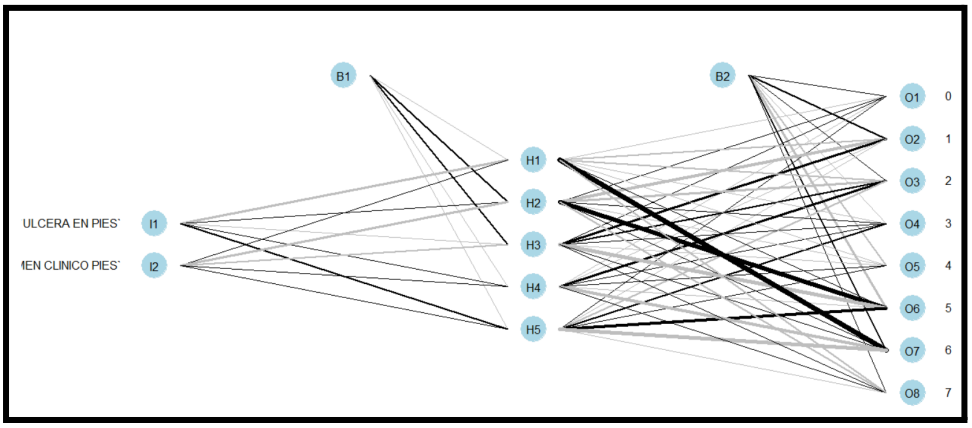




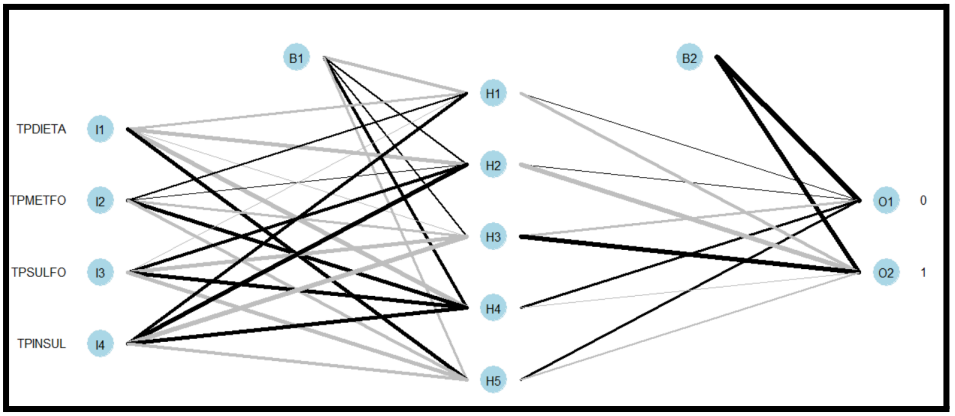
REDES NEURONALES

Se utilizará la función nnet para construir un modelo que prediga a partir de todas las variables con las que contamos y ver si alguna puede cumplir de forma satisfactoria cuando se compare la parte que se entrena y con la que son de prueba:





Real	Predicho 0	3
0	25628	47
1	922	8
2	106	5
3	2811	54
4	93	2
5	970	9
6	54	0
7	210	10



Real	Predicho 0
0	24148
1	3582

Como se observa tanto en los plots de las redes como en las matrices de confusión, debido al desbalance de observaciones entre las personas que padecen y las que no padecen alguna enfermedad, la red no está aprendiendo bien y apunta a predecir todas las variables de respuesta como 0, ya que tenemos alrededor del 83% de individuos con este valor en RNN. Por lo tanto es complicado el funcionamiento de este modelo y el aprendizaje para predicción, alternativamente se podría quitar como él los otros métodos los individuos con valores 0 en la variable ya antes mencionada. En el caso cuando se trabaja para predecir los individuos con valores "3" qué son los de neuropatía, también predice parte de ellos por el desbalance de frecuencias con respecto a los otros valores de RNN.

CONCLUSIONES

Como hemos visto a lo largo de este proyecto, hemos detectado principalmente que no todos los métodos de análisis estadístico multivariado nos funcionaban para este conjunto de datos con el que contábamos. El principal problema fue la falta de normalidad, pero esto es muy común cuando se estudia o trabaja con datos clínicos de personas. También la falta de correlación entre variables hacía difícil la parte de análisis factorial el cual hubiera sido de gran ayuda para reconocer nuevas variables que pudieran explicar de forma más general el problema del cual partimos.

De igual forma reconocer los modelos que más nos ayudaron para tratar de responder la pregunta de investigación que se planteó al principio de este proyecto, como lo fueron, análisis de conglomerados y Regresión Logística; Los cuales nos dieron más facilidad de interpretación para poder agrupar e identificar los patrones de los cuales estábamos interesados. Ya dicho esto, la parte de los resultados resultaron tambien muy objetivas, ya que se utilizo diversos puntos de vista de los cuales podíamos sacar conclusiones, como comparar solo la variable Neuropatía con las personas que no la padecen; Esto los comparamos con las variables de Ulcera en pies y consulta medica en pies, debido al origen y relación de estos padecimientos. Gracias a la regresión logística se pudo ver como el hecho de que las personas vayan a una consulta medica en pies y padezcan ulceras aumenta considerablemente las probabilidades de que esos individuos padezcan de Neuropatía (9.1 y 3.7 veces respectivamente).

Asi como se comparo de igual manera las personas con padecimientos en general de RNN y las que no tenian ninguno, se pudo observar que en conjunto el IMC fungia como variable protectora contra padecer (disminuye 23%) y por su parte la TAS y Glucosa aumentaban las probabilidades de que los pacientes pudieran padecer algun tipo de RNN.

En el analisis de clusters asi como en componentes principales pudo verse como los individuos que no padecían de ninguna enfermedad predominaban en todo el espacio variable que se explicaba con estas dos primeras componentes principales, entonces tambien dificultaba encontrar patrones de razones que tuvieran mas peso en cuanto a decidir que enfermedad tiene una persona; para esto igual se comparo entre personas con Retinopatía y Nefropatía, donde podia verse como personas con Retinopatia solian estar agrupadas desproporcionadamente en un cluster, siendo menor su presencia en el, tambien en los individuos con Nefropatia podia verse predominancia en uno de los 4 que se escogieron para este caso, con lo cual podemos confirmar la presencia de variables que pesan mas en cuanto a la tendencia a tener alguna de estas dos enfermedades.

Por ultimo, como se observó en componentes principales con nuestras variables continuas, las variables correlacionadas con la variable IMC tendían a representar de mejor manera la primera componente principal, mientras que las presiones arteriales diastolica y sistolica aportaban mas a la segunda, siendo glucosa la menos relevante ya que en ninguna de las dos era significante para representar la varianza de los individuos; Por lo tanto se pudo observar que aunque las personas que no padecian ninguna enfermedad predominaban, el hecho de tener retinopatia, nefropatia y Neuropatia tiene pequeños condicionantes en los signos vitales de las personas pero que en conjunto puede decirnos si es mas probable o no que una persona sufra de estas enfermedades, teniendo igual significancia los tratamientos que lleva y puede mejorar su estado de salud, pero comunmente las personas que ya estan obligadas a llevar un tratamiento como estos suele ya padecer una enfermedad de RNN por lo que estan asociadas entre si.

BIBLIOGRAFÍA

Zaizar-Fregoso, S. A., De la E., I., Hernández-Sánchez, C. M., et al. (2023). Using artificial intelligence to develop a multivariate model with a machine learning model to predict complications in Mexican diabetic patients without arterial hypertension (National nested case-control study): Metformin and elevated normal blood pressure figures as risk factors. Journal of Diabetes Research, 2023, Article 8898958. https://doi.org/10.1155/2023/8898958

*Prasad, B. V. V. S., Mouleswararao, B., & **others** (2023). Adaptive fuzzified K-nearest neighbor for diabetes prediction using medical datasets. **Preventive Medicine, 174**, 107619. https://doi.org/10.1016/j.ypmed.2023.107619*

SyedWasifGillani, et al.(2019) Multivariate Analysis on the Effects of Diabetes and related Clinical Parameters on Cervical Cancer Survival Probability. Scientific Report 9:1084.Recuperado de: https://doi.org/10.1038/s41598-018-37694-1

Jianqing Li, et al.(2019) Correlations among Diabetic Microvascular Complications: A systematic Review and Meta analysis. Scientific Report 9:3137.Recuperado de: | https://doi.org/10.1038/s41598-019-40049-z

Claudia R. L. Cardoso (2015) Increased aortic stiffness predicts future development and progression of peripheral neuropathy in patients with type 2 diabetes: the Rio de Janeiro Type 2 Diabetes. Croos Mark, Diabetologia Recuperado de: https://doi.org/10.1007/s00125-015-3658-9

Platikanov, S., Terrado, M., Pay, M. T., Soret, A., & Tauler, R. (2022). Understanding temporal and spatial changes of O_3 or NO_2 concentrations combining multivariate data analysis methods and air quality transport models. Science of the Total Environment, 806, 150923. https://doi.org/10.1016/j.scitotenv.2021.150923

Guerra, N. Capítulo 20 Análisis Factorial El procedimiento Análisis factorial. Recuperado de: (PDF) Capítulo 20 Análisis Factorial El procedimiento Análisis factorial

Warne, R., (2014) "A Primer on Multivariate Analysis of Variance (MANOVA) for Behavioral Scientists", Practical Assessment, Research, and Evaluation 19(1): 17. doi: https://doi.org/10.7275/sm63-7h70

Alonso, J.C.; Largo, M.F. y Camilo Hoyos, C. (2025). Una introducción a los modelos de Clústering empleando R. Cali: Editorial Universidad Icesi. DOI: https://doi.org/10.18046/EUI/bda.h.6

Platikanov, S., Terrado, M., Pay, M. T., Soret, A., & Tauler, R. (2022). Understanding temporal and spatial changes of O_3 or NO_2 concentrations combining multivariate data analysis methods and air quality transport models. Science of the Total Environment, 806, 150923. https://doi.org/10.1016/j.scitotenv.2021.150923