Reporte de investigación: Clasificacion de personas hipertensas respecto a sus habitos en el dia a dia

FERNANDO GARCIA GUALITO

Mayo, 2026

1. Introduccion

La presión arterial (PA) es la resistencia o fuerza que ejerce la sangre dentro de las arterias, esta se suele expresar con la medida de milímetros sobre mercurio (mmHg). Según [1] "La PA está regulada por mecanismos nerviosos que actúan rápidamente (segundos) modificado la actividad cardíaca (frecuencia y fuerza) y el radio de las arteriolas (resistencia) por mecanismos reflejos autónomos, y por mecanismos endocrinos a largo plazo (horas y días) que actúan sobre el sistema renal, modificando el sodio y agua a través del sistema renina-angiotensina-aldosterona y vasopresina." (p. 147)

La hipertensión arterial o presión arterial alta es causa de miles de muertes al año desde hace mucho tiempo en todo el mundo, dado de que de ella se derivan enfermedades cardiovasculares, cerebrovasculares y también en muchos casos falla renal. En el siglo XVIII un personaje histórico Stephen Hales, botánico, clérigo y fisiólogo, hizo una de las contribuciones más importantes de esa época, midió la presión arterial usando a una yegua y un tubo calibrado que introdujo en la arteria carótida del animal, y pudo comprobar que la sangre aumentaba de altura mediante el animal realizaba movimientos bruscos.[2]

La presión arterial hoy en día se mide como ya se mencionó en milímetros sobre mercurio, una persona tendrá niveles de presión arterial alta cuando se le diagnostique tensión arterial sistólica mayor a 140 mmHg o tensión arterial diastólica mayor a 90 mmHg, ya sea alguna de las dos o ambas esta persona es hipertensa. Por lo contrario si tiene estos niveles de TAS y TAD por debajo de los estándares respectivamente tiene una presión controlada. [3]

Según [4] "el porcentaje de personas con hipertensión arterial es directamente proporcional a la edad, es decir, la prevalencia de esta enfermedad se eleva a medida que aumenta la edad. Como se había mencionado anteriormente, los factores de riesgo pueden verse modificados dependiendo de la persona."

En cuestión a la actividad física es bastante difícil encontrar una asociación directa a los niveles de presión arterial, esto por diversos factores, ya que al realizar actividad física se vio una disminución de peso en las personas. El IMC si tuvo una relación significativa con los niveles de PA y en un experimento de 55 personas específicas, se hicieron 3 pruebas, en las que un grupo aleatorio hiciera ejercicio con ciertas recomendaciones, otro una dieta resaltando la disminución de alcohol y sal, y la tercera incluyendo las dos anteriores. Se observó que los resultados antihipertensivos no son aditivos.[5]

2. Metodologia

Como tecnica principal se uso una tecnica usada en clase llamada KNN que nos ayuda a clasificar a las personas hipertensas; Según [6], el algoritmo K-Nearest Neighbors (KNN) es un método de aprendizaje supervisado basado en proximidad, en el cual la clasificación de una nueva observación depende de las k observaciones más cercanas dentro del espacio de características. El modelo asigna la categoría predominante entre dichos vecinos, asumiendo que observaciones similares tienden a pertenecer a la misma clase. Además, KNN no requiere asumir distribuciones estadísticas específicas para los datos, aunque su desempeño depende de la elección adecuada de k y del escalamiento de las variables.

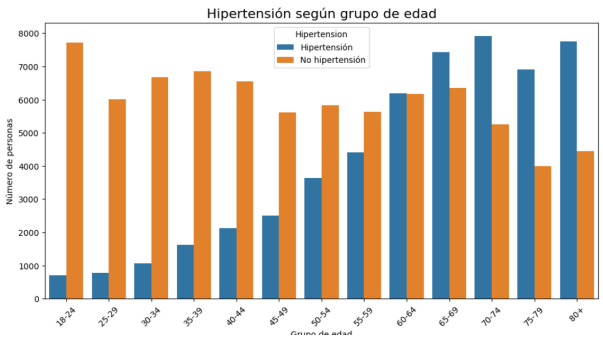
Tambien se utilizó la regresión logística para analizar probabilidades dependiendo de los grupos donde se encontrarán las personas. La regresión logística es una herramienta de análisis multivariado que tiene por fines explicar e incluso predecir, con variables de respuesta o dependientes dicotómicas, y variables independientes continuas o categóricas.[7]. Así como en un modelo de regresión lineal múltiple, tendremos una ecuación de coeficientes predictores para la variable dependiente.[7] "Para la estimación de los coeficientes del modelo y de sus errores estándar se recurre al cálculo de estimaciones de máxima verosimilitud, es decir, estimaciones que hagan máxima la probabilidad de obtener los valores de la variable dependiente Y proporcionados por los datos de nuestra muestra."[7]

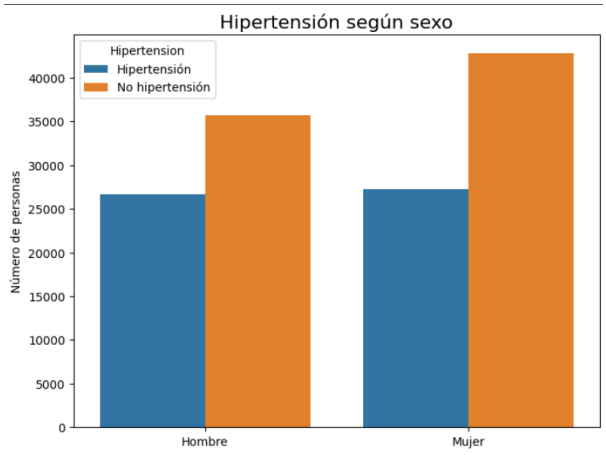
Los datos fueron obtenidos de la CDC(The Centers for Disease Control and Prevention) o en español, Centros para el Control y Prevención de Enfermedades. Esta es una organización oficial del gobierno de los Estados Unidos de América. Específicamente se entró a las encuestas de la BRFSS (Behavioral Risk Factor Surveillance System), o en español, Sistema de Vigilancia de Factores de Riesgo Conductuales. Este del año 2023 (mas reciente), puede consultarse en este sitio web: CDC - 2023 BRFSS Survey Data and Documentation Donde encontraremos la base de datos, como 2023 BRFSS Data (SAS Transport Format) en la sección de DATA FILES (para mayor versatilidad se convirtió en un documento csv) En este sitio web también contamos con distintos archivos de apoyo para el análisis, como los Cuestionarios, Explicación de las variables, y tablas de variables calculadas.Esta encuesta tiene 133,032 respuestas de distintas personas de la mayoría de estados pertenecientes a USA.

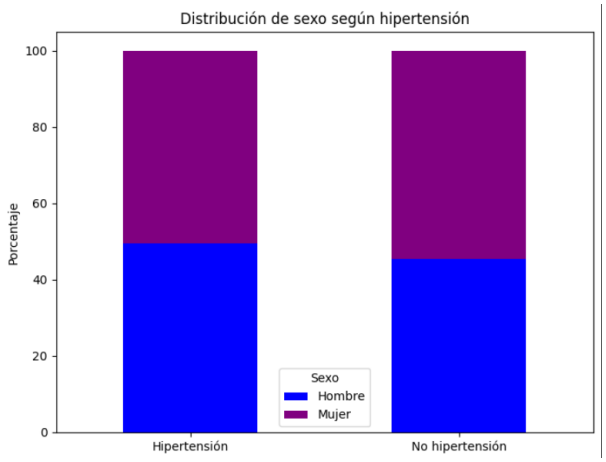
Vamos a prestar atencion a la variable binaria RFHYPE6 que indica personas que han sido diagnosticadas con presion arterial alta o no. Y tambien consideramos otras variables como lo son el Sexo, Edad, Indice de Masa Corporal Intensidad de Actividad fisica, 2 tipos de adicciones como los son el Alcohol y el cigarrillo. Asi tratando de identificar patrones entre los habitos de las personas.

3. Estadistica descriptiva

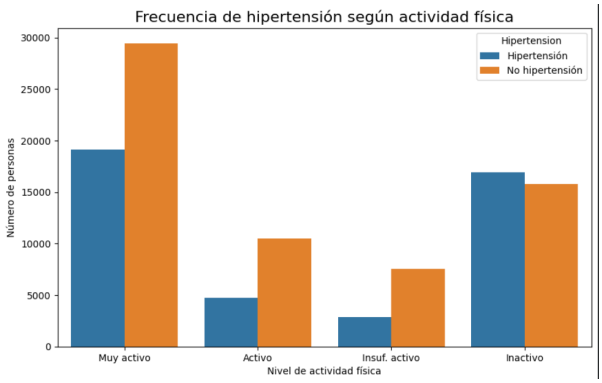
Como primer paso analicemos los comportamientos entre los grupos de personas en las diferentes variables de interes, respecto a las personas que tienen y no hipertension.
Primero se presenta las distribuciones segun la edad y sexo; donde puede verse a simple vista diferencias significativas con la edad, asi mismo cuando miramos el sexo pues notamos una menor tendencia de las mujeres a sufrir hipertension con cerca de un 62 % y por su parte los hombres con un 57 %



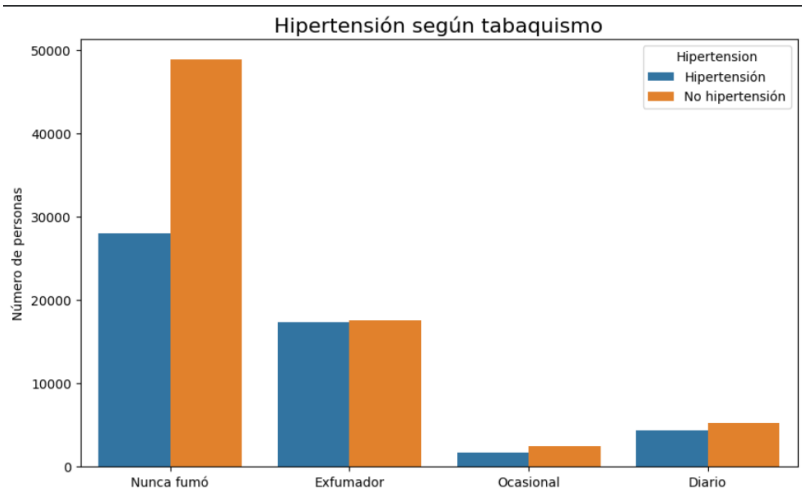




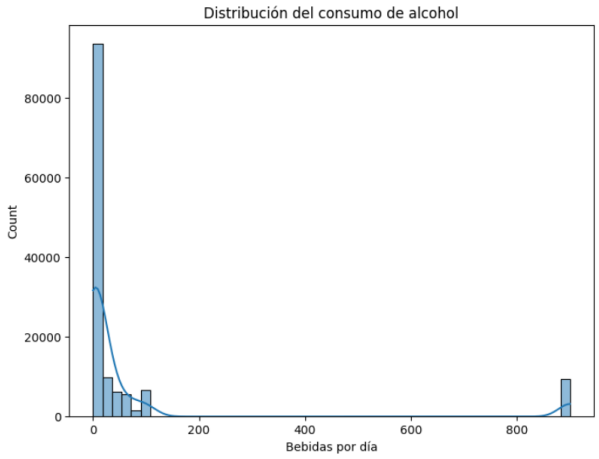
Intensidad de actividad fisica: en la cual observamos primero que la mayoria de personas tiene una vida muy activa mientras que segunda mayor cantidad de personas son aquellas que su actividad fisica en nula, en esta ultima tenemos un 55 % con hipertension mientras que en las personas activas tan solo un 40 %

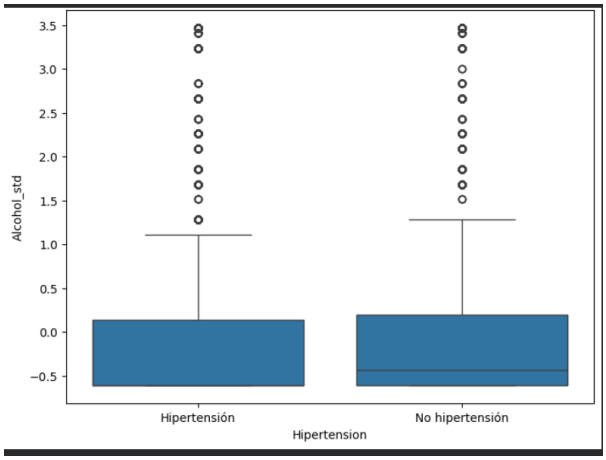


Con la variable SMOKER3 que representa la situacion de tabaquismo de cada persona (variable ordinal) con 1 como fumador compulsivo y 4 nunca fumo.

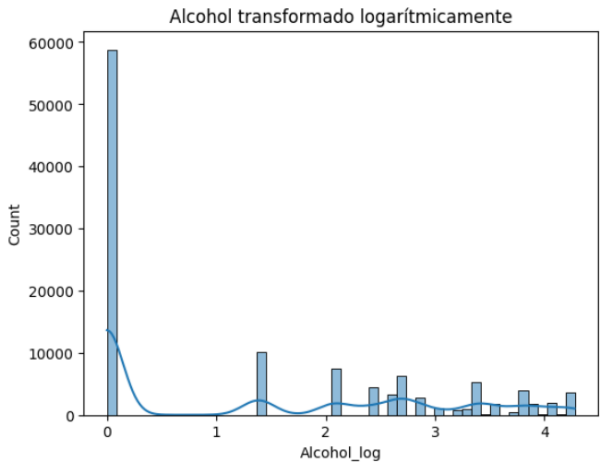


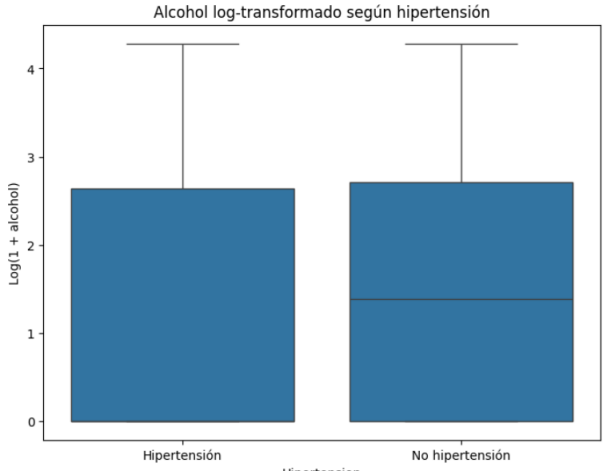
Despues la variable de alcoholismo que es una variable continua que representa muy bien el nivel de alcoholismo de una persona ya que continiene el numero de tragos que consumen en promedio al dia. Para esta la analizamos con mayor cuidado y la convertimos en logaritmica para mejorar su interpretacion:





Aqui el diagrama de caja con la variable ya estandarizada y tambien la distribucion con una logaritmica.





4. IMPLEMENTACION DE KNN

Se realizo un modelo de clasificacion basado en la tecnica clasificadora de KNN, con ayuda de python para analizar nuestra base de datos y las variables correspondientes.

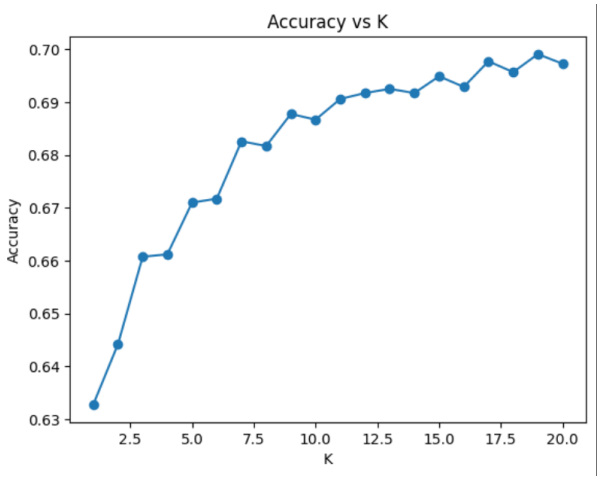
Con la preparacion ya hecha de las variables objetivo y predicoras primero observamos las precisiones de nuestro modelo. En el que observamos numeros por encima de 60 % y que al momento de aumentar los vecinos a k=11 pueden subir tales numeros. Pero sin ser muchisimo mejor.

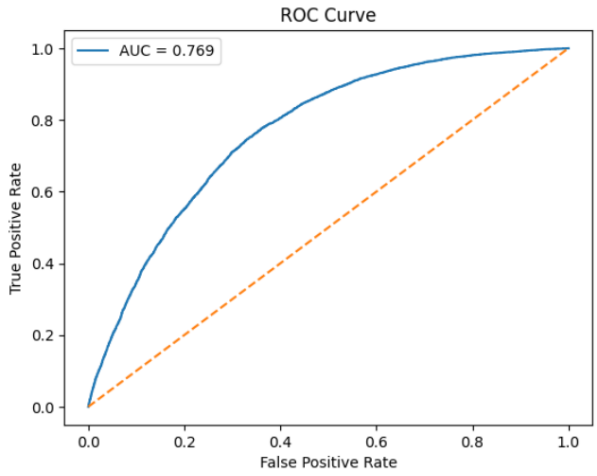
	precision	recall	f1-score	support
0	0.72	0.74	0.73	12794
1	0.60	0.57	0.58	8669
accuracy			0.67	21463
macro avg	0.66	0.66	0.66	21463
weighted avg	0.67	0.67	0.67	21463

K = 11

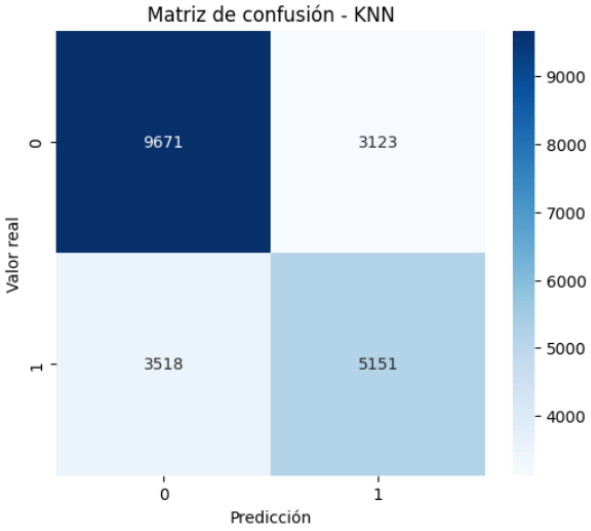
	precision	recall	f1-score	support
0	0.73	0.76	0.74	12794
1	0.62	0.59	0.61	8669
accuracy			0.69	21463
macro avg	0.68	0.68	0.68	21463
weighted avg	0.69	0.69	0.69	21463

Notando como con la implememntacion de mas k, se estabiliza y no tiende a mejorar, ademas que entre mayor sea k pues menos interesante es el modelo.





Matriz de Confusion: Por ultimo para nuestro modelo veamos la matriz de confusion, en el cual vemos que nuestro modelo no es tan preciso, en el cual tenemos aun bastantes falsos negativos (3123):



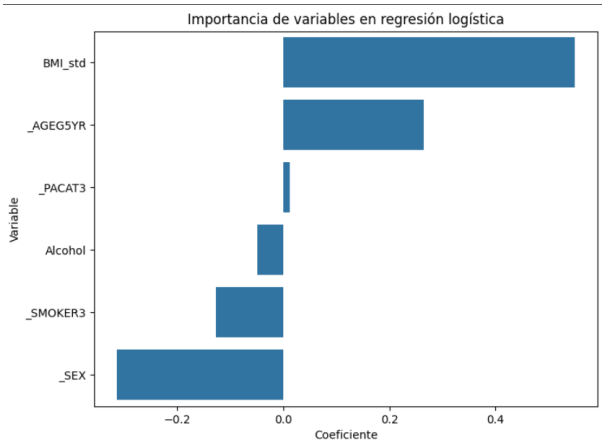
5. REGRESION LOGISTICA

En contraste a el modelo KNN vamos a desarrolllar una regresion logistica que es conveniente para este tipo de variable y que aparte de clasificar nos puede proporcionar mas informacion acerca de como nuetras variables se relacionan entre si para dar probabilidades al hecho de padecer hipertension o no. Analizando nuevamente nuestra tabla de preciosiones tenemos

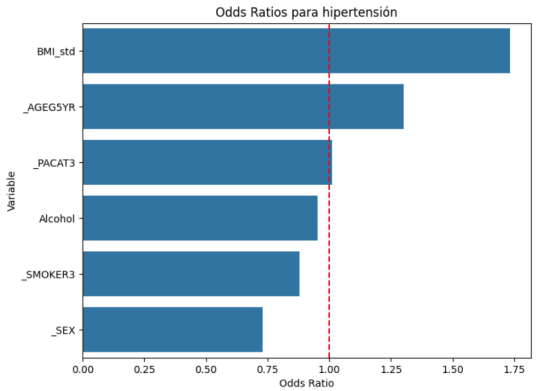
	precision	recall	f1-score	support
0	0.74	0.77	0.75	12794
1	0.64	0.60	0.62	8669
accuracy			0.70	21463
macro avg	0.69	0.68	0.69	21463
weighted avg	0.70	0.70	0.70	21463

En la cual observamos mayor certeza a la hora de predecir, lo cual es una muy buen noticia. Vamos a observar sus odds ratios para poder analizar probabilidades:

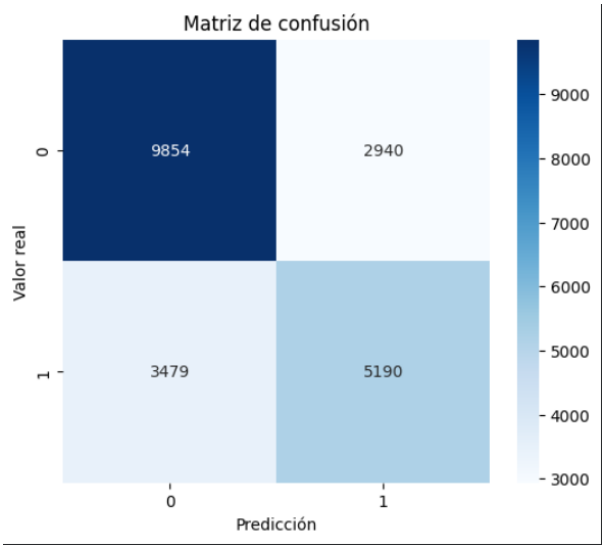
	Variable	Coeficiente	Odds_Ratio
5	BMI_std	0.548869	1.731294
0	_AGEG5YR	0.264653	1.302979
2	_PACAT3	0.012631	1.012711
4	Alcohol	-0.049005	0.952177
3	_SMOKER3	-0.127012	0.880723
1	_SEX	-0.313064	0.731203



Se puede observar comoo hay cierta inclinacion a la variable de Masa Corporal ya que cuando aumentamos una unidad de desviacion estandar a la media, tenemos un 73 % mas de probabilidad de padecer, mientras que con la edad tambien por cada rango de 5 años en el que aumentemos tendremos aproximadamente 30 % mas probabilidad de tener hipertension. Por parte de la actividad fisica no se encuentra algo significante ya que solo contamos con odd ratio de 1.01, por parte del alcohol se tiene una proporcion inversa que marca un 5 % menos cada que vaya aumentando, y el ser menos constante en el consumo del tabaco disminuye casi un 12 % de las probabilidades de padecer. Finalmente en cuanto al sexo debido a la codificacion esto indica que las mujeres tienen un poco mas de 26 % menos probabilidad de tener hipertension.



Finalmente miremos la matriz de confusion, donde hemos logrado bajar un poco los falsos:



	Modelo	Accuracy	Recall HTA	F1-score
0	Regresión Logística	0.701	0.599	0.618
1	Random Forest	0.664	0.568	0.577

6. CONCLUSIONES

Ya vistos los resultados, no se puede mas que reafirmar que para una trabajo con algunas herramientas un poco limitadas no es posible hacer cara al problema de clasificacion de la hipertension en un rango de edad de 18 a 99 años en el que si bien tuvimos algunos resultados, los modelos desarrollados aun no son lo suficientemente buenos para que se pueda confiar en ellos. Aunque gracias a la implemetacion de la regresion logistiaca es posible afirmar que el indice de masa corporal que esta asociado a los habitos de las personas como el sedentarismo y alimentacion del cual se derivan multiples enfermedades esta fuertemente asociado a las probabilidades de tener hipertension. Esta variable y la edad son las que mas importantes son a la hora de hacer este analisis con nuestras variables que se estan relacionando. Por otra parte el tabaquismo y alcoholismo vemos que pueden ser factor a la hora de padecer esta enfermedad y evitar el consumo en una buena iniciativa para disminuir las probabilidades de padecer esto y empezar desde edad temprana a tener enfermedades derivadas de la hipertencion. La actividad fisica aunque no haya marcado una odd ratio significativo, sabemos que esta relacionada directamente con el IMC lo cual en la practica ya pone una ventaja ante las personas que busquen cuidar su salud. Los modelos siguen siendo mas deficientes que muy buenos pero pueden llegar a mejorarse, suelen llegar a equivocarse y cuando hablamos de falsos negativos es preocupante.

7. BIBLIOGRAFIA

@bookbishop2006pattern, author = Christopher M. Bishop, title = Pattern Recognition and Machine Learning, year = 2006, publisher = Springer

@articleplatikanov2022understanding, author = Platikanov, Sergi and Terrado, Marc and Pay, Maria Teresa and Soret, Albert and Tauler, Romà, title = Understanding Temporal and Spatial Changes of O_3 or NO_2 Concentrations Combining Multivariate Data Analysis Methods and Air Quality Transport Models, journal = Science of the Total Environment, volume = 806, pages = 150923, year = 2022, doi = 10.1016/j.scitotenv.2021.150923 @articlebahamonde2020desarrollo, author = Bahamonde, N. and Cremer, M. C. and Mut, P. N. and Lozano, E., title = El desarrollo de una línea disciplinar para la enseñanza del modelo de presión arterial en la formación del profesorado en biología, journal = Tecné, Episteme y Didaxis: TED, number = 47, pages = 143–159, year = 2020, issn = 2665-3184, url = https://www.redalyc.org/articulo.oa?id=614270238009

@bookgil2020hipertension, author = Gil Extremera, Baltasar, title = Hipertensión arterial: Estado actual, publisher = Editorial Universidad de Granada, year = 2020, url = https://editorial.ugr.es/libro/hipertension-arterial$_1$37408/

@articlecampos2013hipertension, author = Campos-Nonato, Ismael and Hernández-Barrera, Lucía and Rojas-Martínez, Rosalba and Pedroza, Adolfo and Medina-García, Catalina and Barquera-Cervera, Simón, title = Hipertensión arterial: prevalencia, diagnóstico oportuno, control y tendencias en adultos mexicanos, journal = Salud Pública de México, volume = 55, number = Suppl. 2, pages = S144–S150, year = 2013, url = http://www.scielo.org.mx/scielo.php?script
$S0036 - 36342013000800011$

@articlealvarez2022factores, author = Álvarez-Ochoa, R. and Torres-Criollo, L. M. and Garcés Ortega, J. P. and Izquierdo Coronel, D. C. and Bermejo Cayamcela, D. M. and Lliguisupa Pelaez, V. del R. and Saquicela Salinas, A. S., title = Factores de riesgo de hipertensión arterial en adultos: Una revisión crítica, journal = Revista Latinoamericana de Hipertensión, volume = 17, number = 2, pages = 45–52, year = 2022, url = https://www.revhipertension.com/rlh$_2$2022/7$_f actores_r iesgo_h ipertension_a rterial.pdf$

@articlecoll1998modificaciones, author = Coll de Tuero, G. and Salleras Marcó, N., title = Modificaciones del estilo de vida en pacientes hipertensos, journal = Atención Primaria, volume = 22, number = 9, pages = 596–606, year = 1998, url = https://www.elsevier.es/es-revista-atencion-primaria-27-articulo-modificaciones-del-estilo-vida-pacientes-14975